



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

ProcureWatch Analytics:
Planteamiento Metodológico

Trabajo Fin de Estudios

presentado por: Sebastián Alfonso Correa y Saturía María Hurtado Álvarez

Dirigido por: Marlon Cárdenas Bonett

Ciudad: Madrid

Fecha: 22 de abril de 2026

Índice de Contenidos

Prefacio	IV
1. Planteamiento Metodológico	1
1.1. Enfoque General	1
1.2. Fases de Trabajo	1
1.2.1. Fase 0: Configuración del Entorno (Semanas 1-2)	1
1.2.2. Fase 1: Comprensión del Dominio (Semanas 3-4)	1
1.2.3. Fase 2: Preparación de Datos (Semanas 5-6)	2
1.2.4. Fase 3: Motor de Red Flags (Semanas 7-9)	3
1.2.5. Fase 4: Análisis de Redes y NLP (Semanas 10-12)	3
1.2.6. Fase 5: Sistema Multiagente y Front-end (Semanas 13-14)	4
1.2.7. Fase 6: Evaluación y Refinamiento (Semanas 15-16)	5
1.2.8. Fase 7: Documentación y Cierre (Semanas 17-18)	6
1.3. Organización del Equipo	6
1.3.1. Sebastián Alfonso Correa	6
1.3.2. Saturía María Hurtado Álvarez	7
1.3.3. Sincronización y Coordinación	8
1.4. Entregables por Fase	8
1.5. Criterios de Calidad y Validación	8
1.5.1. Criterios técnicos por módulo	8
1.5.2. Criterios de reproducibilidad	8
1.5.3. Criterios de pertinencia académica	9
2. Gestión de Riesgos y Contingencias	11
2.1. Riesgos Identificados	11
2.1.1. Riesgo 1: Calidad de datos inferior a expectativas	11
2.1.2. Riesgo 2: Alcance técnico demasiado ambicioso	11
2.1.3. Riesgo 3: Dificultades en integración multiagente	11
A. Estructura de Carpetas del Proyecto	12

B. Reuniones y Hitos Clave	13
B.1. Calendario de Reuniones	13
B.2. Hitos Críticos	13

Índice de Ilustraciones

Índice de Tablas

1.1. Resumen de fases, entregables y responsables	10
---	----

Prefacio

Este documento contiene el planteamiento metodológico detallado del proyecto ProcureWatch Analytics. Describe las fases de trabajo, organización del equipo, cronograma, entregables y criterios de calidad para la ejecución del Trabajo Fin de Máster.

1. Planteamiento Metodológico

1.1. Enfoque General

El proyecto sigue una **metodología iterativa adaptada de CRISP-DM** para la componente analítica, combinada con **desarrollo incremental por módulos** para el prototipo. Esta aproximación permite validación temprana de hipótesis, integración progresiva de módulos y feedback continuo.

1.2. Fases de Trabajo

1.2.1. Fase 0: Configuración del Entorno (Semanas 1-2)

Objetivo: Preparar infraestructura técnica y recursos formativos.

Actividades:

- Instalación local: Python, Docker, Ollama, PostgreSQL, Neo4j Community
- Setup de repositorio GitHub con estructura de carpetas
- Cursos introductorios: Python para DA, Fundamentos de IA

Entregables: Entorno funcional, repositorio inicializado, documentación de setup.

Responsables: Ambos **Duración:** 2 semanas

1.2.2. Fase 1: Comprensión del Dominio (Semanas 3-4)

Objetivo: Entender estructura del ciclo contractual español y caracterizar calidad de datos.

Actividades:

- Exploración estadística del dataset BOE 2014-2024
- Análisis comparativo PLACE vs BOE
- Documentación del ciclo contractual español
- Revisión de red flags en literatura (OCP 2024, DIGIWHIST)

- Elaboración de matriz: Variables OCDS $\times$ Indicadores de red flags

Entregables:

1. Informe de análisis exploratorio (EDA report) con gráficos y estadísticas descriptivas
2. Documento técnico de mapeo: campos OCDS $\rightarrow$ indicadores de red flags
3. Lista priorizada de red flags a implementar (mínimo 15)
4. Presentación interna con hallazgos y recomendaciones

Responsables: Ambos (complementarios) **Duración:** 2 semanas

1.2.3. Fase 2: Preparación de Datos (Semanas 5-6)

Objetivo: Construir pipeline de datos limpio, normalizado y disponible para análisis.

Actividades:

- Implementación del pipeline ETL: descarga, validación, limpieza, normalización OCDS
- Resolución de inconsistencias: duplicados, fechas incoherentes, importes negativos, NIFs malformados
- Enriquecimiento: integración con datos de registro mercantil (cuando disponible)
- Carga en PostgreSQL con validaciones post-insert
- Construcción del grafo empresa-organismo en Neo4j usando Python driver

Entregables:

1. Script pipeline reproducible y documentado (pipeline.py)
2. Base de datos PostgreSQL con esquema OCDS completo: mínimo 97.000 contratos, 2.000+ organismos, 15.000+ empresas
3. Grafo Neo4j operacional con estructura verificable
4. Reporte de calidad post-carga (completitud, coherencia temporal, duplicados)

Responsable: Sebastián (lead pipeline), Saturía (apoyo) **Duración:** 2 semanas

1.2.4. Fase 3: Motor de Red Flags (Semanas 7-9)

Objetivo: Implementar y validar indicadores de red flags y modelos de scoring.

Actividades:

- Codificación de 15+ indicadores (RF-01 a RF-06 y variantes) en SQL/Python
- Implementación de scoring compuesto: base score + bonus/penalty por métricas de red
- Comparativa de tres enfoques: reglas OCDS explícitas vs. Isolation Forest vs. Positive-Unlabeled Learning
- Validación parcial: análisis de precisión sobre casos documentados (contratos menores con licitación única verificables)
- Ajuste de umbrales y pesos según resultados

Entregables:

1. Módulo de red flags implementado (red_flags.py) con documentación de cada indicador
2. Scoring por contrato y por adjudicatario disponible en BD
3. Comparativa técnica: tablas y gráficos de rendimiento de tres enfoques
4. Ranking de red flags por frecuencia de activación y correlación con casos documentados

Responsable: Sebastián (lead) **Duración:** 3 semanas

1.2.5. Fase 4: Análisis de Redes y NLP (Semanas 10-12)

Objetivo: Análisis relacional (comunidades, centralidades) y extracción documental.

Subactividad 4a — Análisis de Redes (Saturía):

- Ejecución de algoritmo Leiden en grafo empresa-organismo: detección de comunidades
- Cálculo de métricas de centralidad: degree, betweenness, eigenvector

- Detección de patrones anómalos: adjudicatarios con centralidad extrema, comunidades mal conectadas
- Correlación entre métricas de red y scores de red flags

Subactividad 4b — NLP y OCR (Saturía):

- OCR de pliegos y resoluciones con Docling
- Extracción de entidades con spaCy (organismos, importes, plazos, proveedores)
- Construcción de corpus indexado en Qdrant (vector database)
- Implementación de motor RAG híbrido (dense retrieval + sparse retrieval)

Entregables:

1. Informe de análisis de comunidades: número, tamaño, modularidad, patrones atípicos
2. Corpus documental procesado y indexado (5.000 documentos)
3. Motor RAG funcionando con métricas RAGAS documentadas
4. Visualización: grafo interactivo con comunidades coloreadas, centralidades etiquetadas

Responsable: Saturía (lead ambas subactividades) **Duración:** 3 semanas

1.2.6. Fase 5: Sistema Multiagente y Front-end (Semanas 13-14)

Objetivo: Integrar todos los módulos en plataforma cohesiva.

Actividades:

- Integración de agentes con LangGraph: orquestación de pipeline → red flags → redes → NLP
- Implementación de front-end con Streamlit + Plotly + Sigma.js
- Componentes: grafo interactivo, panel de indicadores, timeline, ficha explicativa
- Conexión backend (APIs FastAPI) ↔ front-end
- Tests end-to-end: flujos completos de usuario

Entregables:

1. Plataforma integrada y funcional (demo ejecutable)
2. Interfaz web con componentes interactivos
3. API REST documentado (OpenAPI/Swagger)
4. Guía de usuario técnico

Responsables: Ambos (Sebastián back-end, Saturía front-end) **Duración:** 2 semanas

1.2.7. Fase 6: Evaluación y Refinamiento (Semanas 15-16)

Objetivo: Validación rigurosa del prototipo con métricas cuantitativas y cualitativas.

Actividades:

- Ejecución de suite de pruebas: pipeline quality, red flags precision/recall, RAG metrics, usability SUS
- Análisis detallado de 10-15 casos de riesgo: comparación scoring sistema vs. realidad documentada
- Refinamiento de pesos, umbrales, modelos basado en resultados
- Documentación de limitaciones, gaps, roadmap futuro

Entregables:

1. Informe de evaluación completo con todas las métricas
2. Análisis de casos: fichas técnicas de 10-15 contratos analizados
3. Documento de lecciones aprendidas y mejoras futuras

Responsables: Ambos **Duración:** 2 semanas

1.2.8. Fase 7: Documentación y Cierre (Semanas 17-18)

Objetivo: Redacción de memoria TFM, documentación técnica y preparación de defensa.

Actividades:

- Redacción de memoria TFM siguiendo estructura UNIR: introducción, estado del arte, objetivos, metodología, resultados, conclusiones
- Documentación técnica exhaustiva (architecture, APIs, ejemplos)
- Preparación de repositorio GitHub público con código, datos (subset) y documentación
- Ensayos de presentación y defensa

Entregables:

1. Memoria TFM completa y editada (100-150 páginas)
2. Repositorio GitHub con código fuente, documentación, ejemplos reproducibles
3. Presentación para defensa (20-25 minutos)

Responsables: Ambos **Duración:** 2 semanas

1.3. Organización del Equipo

El equipo consta de **dos investigadores** con roles complementarios:

1.3.1. Sebastián Alfonso Correa

Especialidad: Pipeline de datos, modelado analítico, machine learning, scoring

Responsabilidades principales:

- Fase 2: Diseño e implementación del pipeline ETL (lead)
- Fase 3: Desarrollo del motor de red flags (lead)
- Fase 5: Back-end, APIs, orquestación de agentes

- Apoyo transversal en validación de datos

Entregables específicos:

- Pipeline reproducible (clean_data.py, load_database.py)
 - Módulo de red flags (red_flags.py, scoring.py)
 - API backend (FastAPI, main.py)
 - Documentación técnica de arquitectura
-

1.3.2. Saturía María Hurtado Álvarez

Especialidad: Análisis de redes, NLP, procesamiento de documentos, visualización

Responsabilidades principales:

- Fase 1: Análisis exploratorio y matriz de mapeo (co-lead)
- Fase 4: Análisis de grafos y redes (lead)
- Fase 4: NLP, OCR y motor RAG (lead)
- Fase 5: Front-end y componentes de visualización
- Apoyo en evaluación cualitativa de casos

Entregables específicos:

- Análisis exploratorio (eda_report.py)
 - Módulo de análisis de redes (network_analysis.py)
 - Pipeline NLP (nlp_pipeline.py, rag_engine.py)
 - Front-end interactivo (streamlit_app.py)
 - Visualizaciones (grafo interactivo, dashboards)
-

1.3.3. Sincronización y Coordinación

- **Reuniones semanales de equipo:** revisión de progreso, blockers, decisiones de diseño
 - **Hito de revisión de Fase 2/3:** validación de datos y scoring antes de avanzar a redes
 - **Integración progresiva:** módulos se desarrollan en paralelo pero con interfaces claras (BD, APIs)
 - **Testing compartido:** cada módulo debe pasar tests del otro antes de mergear a rama principal
-

1.4. Entregables por Fase

Duración total: 18 semanas (4.5 meses)

1.5. Criterios de Calidad y Validación

1.5.1. Criterios técnicos por módulo

- **Pipeline:** completitud OCDS $> 90\%$, coherencia temporal $> 98\%$
- **Red Flags:** precisión $> 70\%$, estabilidad $\pm 10\%$
- **Redes:** modularidad $Q > 0,30$, correlación con flags $\geq 0,45$
- **NLP/RAG:** Faithfulness > 0.80 , Answer Relevancy > 0.75 , Context Recall > 0.70
- **Front-end:** SUS > 68 , tiempo medio caso < 5 minutos

1.5.2. Criterios de reproducibilidad

- Código completamente documentado y versionado en GitHub
- Scripts ejecutables con ejemplos reproducibles

- Dataset base (subset de BOE) incluido en repo o con instrucciones de descarga
- Docker compose para despliegue local

1.5.3. Criterios de pertinencia académica

- **Estado del arte:** mínimo 10 referencias académicas en formato APA por bloque temático
- **Contribución clara:** gap identificado y cerrado vs. literatura existente
- **Rigor metodológico:** métricas estándar de la literatura adaptadas a contexto español

Tabla 1.1: Resumen de fases, entregables y responsables

Fase	Nombre	Entregables clave	Responsables	Sem
0	Configuración	Entorno, repo, cursos	Ambos	2
1	Análisis explorat.	EDA report, matriz vars-flags	Ambos	2
2	Preparación	Pipeline, BD, grafos	Sebastián	2
3	Motor	Módulo RF, scoring, comparativa	Sebastián	3
4a	Análisis redes	Comunidades, patrones	Saturía	3
4b	NLP/OCR	Corpus, motor RAG	Saturía	3
5	Front-end integrado	Plataforma, APIs, interfaz	Ambos	2
6	Evaluación	Informe eval., casos, roadmap	Ambos	2
7	Cierre	Memoria, repo, presentación	Ambos	2

2. Gestión de Riesgos y Contingencias

2.1. Riesgos Identificados

2.1.1. Riesgo 1: Calidad de datos inferior a expectativas

Probabilidad: Media — **Impacto:** Alto

Mitigación:

- Fase 1: análisis exhaustivo de completitud antes de comprometer Phase 2
- Identificar fuentes complementarias (registros mercantiles, ROLECE)
- Documentar limitaciones de calidad en reporte final

2.1.2. Riesgo 2: Alcance técnico demasiado ambicioso

Probabilidad: Media — **Impacto:** Alto

Mitigación:

- Priorizar MVP (red flags básicos + grafo) sobre funcionalidades avanzadas
- Hito de revisión en Fase 3: evaluar scope vs. tiempo disponible
- Documentar funcionalidades descartadas como trabajo futuro

2.1.3. Riesgo 3: Dificultades en integración multiagente

Probabilidad: Media — **Impacto:** Medio

Mitigación:

- Interfaces claras entre módulos (BD + APIs documentadas)
- Testing early and often
- Slack de 1 semana en Fase 5 para integración

—

A. Estructura de Carpetas del Proyecto

```
procurewatch-analytics/  
  data/  
    raw/          # Datos descargados sin procesar  
    processed/    # Datos limpios y normalizados  
    external/     # Datos complementarios  
  src/  
    pipeline/     # Pipeline ETL  
    red_flags/    # Motor de red flags  
    networks/     # Análisis de redes  
    nlp/          # NLP y RAG  
    frontend/     # Interfaz web  
  notebooks/     # Análisis exploratorio  
  tests/         # Suite de pruebas  
  docs/          # Documentación  
  docker-compose.yml  
  requirements.txt  
  README.md
```

B. Reuniones y Hitos Clave

B.1. Calendario de Reuniones

- **Semanal (lunes 10:00):** Reunión de sincronización equipo (30 min)
- **Bi-semanal (viernes 16:00):** Review con director de tesis (1 hora)
- **Fin de fase:** Presentación de hitos y entregables (1.5 horas)

B.2. Hitos Críticos

1. **Semana 2:** Entorno completamente funcional
2. **Semana 4:** BD poblada con datos limpios y validados
3. **Semana 9:** Motor de red flags funcional (MVP)
4. **Semana 12:** Análisis de redes y NLP completados
5. **Semana 14:** Plataforma integrada y funcional
6. **Semana 16:** Evaluación completa y documentación
7. **Semana 18:** Memoria TFM y presentación listos para defensa