



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

ProcureWatch Analytics: Plataforma Multiagente para la Detección de Patrones de Riesgo en Contratación Pública mediante Open Data, Análisis de Redes, NLP y Modelos Locales

Trabajo Fin de Estudios

presentado por: Sebastián Alfonso Correa y Saturía María Hurtado Álvarez

Dirigido por: Enrique de Miguel Ambite

Ciudad: Madrid

Fecha: 22 de abril de 2026

Índice de Contenidos

Resumen	VI
Abstract	VII
1. Introducción	1
1.1. Motivación y justificación del tema	1
1.2. Planteamiento del trabajo	1
1.3. Estructura del trabajo	2
2. Análisis del Contexto	3
2.1. Dimensión económica de la contratación pública en España	3
2.2. Pregunta 1: Volumen de contratos en PLACE y organismos participantes .	3
2.3. Pregunta 2: Tipos de irregularidades documentadas en España (2014–2024)	4
2.4. Pregunta 3: Limitaciones de los sistemas actuales de auditoría y control .	5
2.5. Pregunta 4: Evidencia de eficacia del análisis de datos para detectar riesgo .	6
2.6. Dominio de análisis seleccionado: CPV 71 — Servicios de arquitectura, in-	
geniería e inspección	7
2.7. Brecha identificada: posicionamiento del proyecto	8
3. Contexto y Estado del Arte	10
3.1. Introducción: criterios de inclusión y organización	10
3.2. Bloque A: Open Data de contratación pública y estándar OCDS	10
3.2.1. El estándar OCDS como eje de integración	10
3.2.2. Fuentes de datos europeas y plataformas de referencia	11
3.3. Bloque B: Red flags, indicadores de riesgo y machine learning	11
3.3.1. Taxonomía de red flags en contratación pública	11
3.3.2. Machine learning aplicado a la detección de fraude	12
3.3.3. Positive-Unlabeled Learning	12
3.3.4. Detección de anomalías no supervisada	12
3.4. Bloque C: Análisis de redes en contratación pública	13
3.4.1. Grafos bipartitos empresa-organismo	13
3.4.2. Detección de comunidades: algoritmos Louvain y Leiden	13

3.5. Bloque D: NLP y procesamiento de documentos de contratación	14
3.5.1. Named Entity Recognition en documentos legales	14
3.5.2. Herramientas NLP para español: spaCy y transformers	14
3.5.3. Web scraping: extracción estructurada de documentos administrativos	15
3.5.4. LLMs locales para análisis jurídico-administrativo	15
3.6. Bloque E: Visualización analítica y explicabilidad	16
3.6.1. Explicabilidad en modelos de scoring de riesgo	16
3.6.2. Visualización de grafos interactivos	16
3.6.3. Dashboards de riesgo	16
3.7. Conclusiones del estado del arte y justificación del proyecto	16
4. Objetivos	18
4.1. Objetivo General	18
4.2. Objetivos Específicos	18
5. Marco Normativo	21
5.1. Implicaciones del AI Act sobre el scoring de riesgo	21
6. Arquitectura Técnica e Implementación del Prototipo	23
6.1. Visión general	23
6.2. Stack tecnológico definitivo	23
6.3. Justificación del uso de IA y LLM	26
6.4. Pipeline de datos	27
6.4.1. Fases del pipeline	27
6.4.2. Modelo de datos analítico	28
6.5. Motor de red flags y scoring	29
6.6. Grafo de contratación	30
6.7. Módulo documental, embeddings y RAG	30
6.8. Implementación multiagente	31
6.9. Interfaz analítica	33
6.10. Trazabilidad, calidad y reproducibilidad	33
6.11. Entregable técnico del 20 de mayo	34
7. Conclusiones y Trabajo Futuro	35
Referencias	35

A. Apéndice: Tipos de contrato incluidos en el análisis	41
--	-----------

Índice de Ilustraciones

6.1. Arquitectura funcional avanzada de ProcureWatch Analytics para la entrega del 20 de mayo de 2026.	24
6.2. Flujo de trazabilidad desde la fuente hasta la ficha explicativa.	33

Índice de Tablas

2.1. Volumen y cobertura de datos disponibles para contratación pública en España y Europa	3
2.2. Gap identificado en la literatura que justifica ProcureWatch Analytics . . .	9
6.1. Stack tecnológico definitivo de ProcureWatch Analytics	24
6.2. Modelo de datos analítico propuesto	28
6.3. Agentes previstos en ProcureWatch Analytics	32
A.1. Subtipos CPV 71 relevantes para ProcureWatch Analytics	41

Resumen

ProcureWatch Analytics es una plataforma analítica multiagente que detecta patrones de riesgo en contratación pública española mediante análisis integrado de datos abiertos (OCDS), indicadores de red flags, análisis de redes societarias (algoritmo Leiden), procesamiento de lenguaje natural sobre documentos públicos y modelos de scoring de anomalías. El sistema aplica su prototipo inicial al dominio CPV 71 (Servicios de arquitectura, ingeniería e inspección), procesando datos del BOE 2014-2024 y PLACE. Valida sus componentes mediante métricas estándar de precisión, modularidad de grafos ($Q \geq 0.30$), calidad RAG (Faithfulness ≥ 0.80) y usabilidad (SUS ≥ 68), generando fichas de riesgo explicables para auditorías públicas.

Palabras clave: contratación pública, red flags, machine learning, análisis de redes, NLP, datos abiertos, CPV 71, OCDS, scoring de riesgo, plataforma multiagente.

Abstract

ProcureWatch Analytics is a multi-agent analytical platform that detects risk patterns in Spanish public procurement through integrated analysis of open data (OCDS), red flag indicators, network analysis (Leiden algorithm), natural language processing over public documents, and anomaly scoring models. The prototype focuses on CPV division 71 (Architecture, Engineering and Inspection Services), processing BOE 2014-2024 and PLACE data. Components are validated using standard metrics: red flag precision, graph modularity ($Q \geq 0.30$), RAG quality (Faithfulness ≥ 0.80) and usability (SUS ≥ 68), generating explainable risk reports to support public audit.

Keywords: public procurement, red flags, machine learning, network analysis, NLP, open data, CPV 71, OCDS, risk scoring, multi-agent platform.

Sebastián Alfonso Correa y Saturía María Hurtado Álvarez
Máster Universitario en Análisis y Visualización de Datos Masivos

1. Introducción

1.1. Motivación y justificación del tema

La contratación pública es uno de los mecanismos de gasto público de mayor volumen económico y mayor exposición al riesgo de irregularidad. En España representa entre el 12 y el 15 % del PIB nacional (OECD, 2016), y desde 2007 la legislación obliga a publicar contratos en formatos abiertos y reutilizables (Jefatura del Estado, 2017). Pese a esta disponibilidad, los análisis sistemáticos, automatizados y reproducibles sobre datos de contratación pública en España siguen siendo escasos.

El reciente *dataset* longitudinal del BOE 2014–2024 (Muñoz Plà, 2026), publicado con aproximadamente 97.000 contratos estructurados según el estándar OCDS, abre una oportunidad concreta para construir análisis de calidad sobre este dominio. La literatura internacional ha demostrado de forma consistente que los métodos de machine learning y análisis de redes mejoran significativamente la detección de irregularidades frente a enfoques puramente basados en reglas explícitas (Wachs, Fazekas, y Kertész, 2025; Fazekas y Cingolani, 2020; Coviello y Mariniello, 2023).

1.2. Planteamiento del trabajo

Este TFM propone diseñar, desarrollar y evaluar **ProcureWatch Analytics**, una plataforma multiagente que integra: (a) un *pipeline* de adquisición e integración de datos Open Data en un estándar OCDS común; (b) un motor analítico de detección de red flags y patrones de riesgo basado en indicadores de la literatura y modelos de machine learning; (c) un módulo documental que extrae mediante *web scraping* criterios de adjudicación, certificaciones y condiciones contractuales desde anuncios y páginas públicas del BOE y PLACE, combinando NLP y RAG para contextualizar los hallazgos; y (d) un *front-end* analítico con red de relaciones interactiva, panel de riesgo, evolución temporal y ficha explicativa de caso.

El prototipo se valida sobre el dominio CPV 71 (Servicios de arquitectura, ingeniería e inspección), seleccionado por razones metodológicas detalladas en la Sección 2.6.

1.3. Estructura del trabajo

- **Capítulo 2** — Análisis del contexto: descripción del problema, datos justificativos, preguntas de investigación y dominio de análisis.
- **Capítulo 3** — Contexto y estado del arte: revisión de los cinco bloques temáticos con referencias académicas y conclusiones sobre la brecha que justifica el proyecto.
- **Capítulo 4** — Objetivos: objetivo general SMART y ocho objetivos específicos medibles y operativos.
- **Capítulo 5** — Marco normativo: legislación de contratación pública, transparencia, protección de datos y análisis de implicaciones del AI Act sobre el scoring de riesgo.
- **Capítulo 6** — Arquitectura técnica e implementación del prototipo: *stack* tecnológico, *pipeline* de datos, motor de red flags, sistema multiagente, RAG documental y visualización.
- **Capítulos posteriores** — Resultados, evaluación, conclusiones y trabajo futuro.

Nota: el planteamiento metodológico detallado (fases, cronograma, entregables) se presenta en el documento independiente `metodologia_tfm.pdf`.

2. Análisis del Contexto

2.1. Dimensión económica de la contratación pública en España

La contratación pública en España constituye uno de los mecanismos de gasto público de mayor impacto económico y social. Representa entre el **12 y el 15 % del PIB nacional** (OECD, 2016), movilizando anualmente decenas de miles de millones de euros en obras, servicios y suministros adjudicados por miles de organismos públicos.

Esta magnitud, sumada a la complejidad de los procedimientos contractuales y a la asimetría de información entre licitadores y organismos, convierte la contratación pública en un ámbito especialmente expuesto al riesgo de irregularidad. Al mismo tiempo, la obligación legal de publicar los contratos en formatos abiertos desde 2007 (Jefatura del Estado, 2017, 2013) genera una base de datos extraordinariamente rica para el análisis de patrones mediante técnicas de datos masivos.

Tabla 2.1: Volumen y cobertura de datos disponibles para contratación pública en España y Europa

Fuente	Volumen	Referencia
Licitaciones anuales PLACE (2024, sin menores)	206.242	Oficina Independiente de Regulación
Contratos BOE 2014–2024 (formato OCDS)	~97.000	Muñoz Plà (2026)
Contratos CPV 71 en dataset BOE	3.443	Muñoz Plà (2026)
Órganos de contratación activos en PLACE	>10.000	Ministerio de Hacienda y Función Pública
Contratos europeos en OpenTender	>19 millones	Government Transparency Institute
Red flags documentados (OCP + DIGIWHIST)	>150 indicadores	Open Contracting Partnership (OCPI)

2.2. Pregunta 1: Volumen de contratos en PLACE y organismos participantes

La Plataforma de Contratación del Sector Público (PLACSP) es el principal sistema de publicación de la contratación pública en España, integrando datos de la Administración General del Estado, comunidades autónomas, entidades locales y el sector público

institucional (Ministerio de Hacienda y Función Pública, 2024).

Según los informes de la Oficina Independiente de Regulación y Supervisión de la Contratación (OIReScon), en el ejercicio 2024 se registraron **206.242 licitaciones** en la plataforma, sin incluir contratos menores, lo que representa una parte sustancial del total de la contratación pública gestionada en España (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025). Si se consideran contratos menores, adjudicaciones y desgloses por lotes, el volumen total de registros anuales asciende a varios millones, aunque esta cifra varía según el criterio de contabilización (contrato, expediente o lote).

En cuanto a los organismos participantes, la plataforma da servicio a **más de 10.000 órganos de contratación activos** pertenecientes a todos los niveles administrativos: Administración General del Estado, comunidades autónomas, diputaciones, ayuntamientos, universidades y entidades del sector público institucional (Ministerio de Hacienda y Función Pública, 2024). Esta fragmentación administrativa supone uno de los principales retos para el análisis sistemático, ya que los datos están distribuidos en múltiples fuentes con formatos y calidades heterogéneas (Open Contracting Partnership, 2023).

2.3. Pregunta 2: Tipos de irregularidades documentadas en España (2014–2024)

La literatura y los informes de supervisión han identificado múltiples tipos de irregularidades en la contratación pública española durante la última década. Las más frecuentes son:

Fraccionamiento indebido de contratos. División artificial de contratos para eludir los umbrales de publicidad y concurrencia. Es uno de los indicadores con mayor soporte empírico en la literatura (Open Contracting Partnership, 2024b, 2016).

Uso inadecuado del contrato menor. Recurso sistemático al procedimiento negociado sin publicidad —que no exige concurrencia— con el mismo proveedor o en importes próximos al umbral legal (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025). Los informes OIReScon han documentado un incremento de este tipo de irregularidades.

Falta de transparencia y publicidad. Procedimientos negociados sin publicidad en contratos que superan umbrales razonables, contratos publicados fuera del horario admi-

nistrativo habitual o en periodos de menor visibilidad (festivos, cierres de ejercicio).

Conflictos de interés y adjudicaciones dirigidas. Caso emblemático: la operación de la Agencia Tributaria en Cantabria (2023), donde se detectaron adjudicaciones sistemáticamente dirigidas a empresas vinculadas a un funcionario responsable de los informes técnicos de valoración (Agencia Tributaria de España, 2023). La AEAT ha señalado explícitamente el cruce entre datos tributarios y contractuales como línea prioritaria de detección.

Modificaciones contractuales injustificadas. Alteraciones del objeto, plazo o importe de contratos ya adjudicados, sin fundamento legal suficiente.

Prácticas colusorias. Empresas adjudicatarias que comparten administradores, domicilios sociales o estructura accionarial, lo que puede indicar coordinación en las ofertas (colusión) o la existencia de grupos empresariales que se presentan formalmente como competidores (Open Contracting Partnership, 2024b).

Sobrecoste y desviaciones de importe. Diferencias sistemáticamente elevadas entre el importe estimado de licitación y el importe real adjudicado, lo que puede indicar estimaciones deliberadamente infladas o reducidas para condicionar la concurrencia (Coviello y Mariniello, 2023).

Los informes recientes de OIREscon (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025) señalan además un aumento significativo de denuncias relacionadas con irregularidades en la adjudicación. En el ámbito académico, Falcón-Cortés, Aldana, y Larralde (2021) demuestran que la concentración de adjudicaciones y la baja concurrencia son los indicadores más predictivos de comportamiento irregular.

2.4. Pregunta 3: Limitaciones de los sistemas actuales de auditoría y control

Los sistemas de control de la contratación pública presentan diversas limitaciones estructurales que justifican el desarrollo de herramientas analíticas avanzadas:

1. **Fragmentación de información.** Los datos están distribuidos entre múltiples plataformas y niveles administrativos, dificultando un análisis global y consistente (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025).

2. **Insuficiencia de recursos de supervisión.** El volumen de contratos gestionados anualmente (¿200.000 licitaciones) excede ampliamente la capacidad de revisión exhaustiva con los medios actuales (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025).
3. **Falta de estandarización y calidad homogénea.** La ausencia de un estándar universal en los formatos de publicación introduce heterogeneidad que dificulta el análisis automatizado (Open Contracting Partnership, 2023).
4. **Carácter reactivo.** Los sistemas de control actúan principalmente una vez detectada la irregularidad, en lugar de prevenirla mediante análisis predictivo (OECD, 2016). Este enfoque reactivo limita la eficacia del sistema.
5. **Ausencia de perspectiva relacional.** Los controles tradicionales no detectan comunidades de proveedores con comportamientos coordinados, ni patrones de concentración atípica que sólo son visibles en el grafo de relaciones empresa-organismo (Wachs y cols., 2025; Martins y cols., 2022).
6. **Invisibilidad del contexto documental.** Los pliegos de prescripciones técnicas, memorias justificativas y resoluciones contienen señales textuales —direccionamientos técnicos, criterios de adjudicación subjetivos— que permanecen invisibles en análisis puramente estructurados (Kalamkar y cols., 2024).

2.5. Pregunta 4: Evidencia de eficacia del análisis de datos para detectar riesgo

La literatura científica reciente ofrece evidencias sólidas sobre la eficacia de los métodos de análisis de datos para la detección de patrones de riesgo en contratación pública:

- Coviello y Mariniello (2023) demuestran, en un estudio empírico con datos de licitaciones italianas, que los indicadores de red flags alcanzan precisiones superiores al 70 % en detección de contratos con corrupción confirmada, especialmente cuando se combinan indicadores de concurrencia, importe y procedimiento.
- Wachs y cols. (2025) aplican un enfoque combinado de machine learning y análisis de redes a datos de contratación en México, demostrando que las métricas de red (cen-

tralidad, comunidades) añaden poder predictivo significativo respecto a los modelos tabulares puros.

- El proyecto europeo DIGIWHIST (Fazekas y Cingolani, 2020; Government Transparency Institute, 2021) desarrolló el *Corruption Risk Index* (CRI) combinando cuatro indicadores observables —riesgo de licitación, conexiones políticas, riesgo del proveedor y riesgo del órgano contratante— con validación sobre datos de 35 jurisdicciones europeas.
- Liu y cols. (2023) proponen el framework PANG (*Pattern-based Anomaly detection in Graphs*) aplicado específicamente a contratación pública, obteniendo mejoras significativas sobre métodos basados en reglas.
- Muñoz Plà (2026) señalan que el *dataset* longitudinal del BOE 2014–2024 permite análisis de patrones estructurales y temporales del riesgo que refuerzan la utilidad del análisis de datos como herramienta de supervisión preventiva.

En conjunto, la evidencia sugiere que la combinación de indicadores de red flags, análisis de grafos y NLP mejora sustancialmente la capacidad de detección temprana respecto a los enfoques de auditoría tradicional.

2.6. Dominio de análisis seleccionado: CPV 71 — Servicios de arquitectura, ingeniería e inspección

Tras el análisis exploratorio del *dataset* BOE 2014–2024, se ha seleccionado la **división CPV 71** (Servicios de arquitectura, construcción, ingeniería e inspección) como dominio de validación del prototipo ProcureWatch Analytics (Portal de Contratación Pública, 2026). Esta división comprende **3.443 contratos adjudicados** con un importe total adjudicado superior a **2.179 millones de euros**, distribuidos entre 394 organismos contratantes y 2.031 empresas adjudicatarias distintas.

La elección se fundamenta en tres criterios metodológicos:

Validez de indicadores de riesgo tabulares. A diferencia del CPV 45 (Obras, $n = 11.808$), los servicios de ingeniería presentan menor incidencia de modificaciones contractuales legalmente justificadas. En obras, las desviaciones de importe son frecuentes y

a menudo legítimas, lo que introduce ruido en los modelos de detección. Los servicios de ingeniería —mayoritariamente estructurados en tarifas horarias y entregables definidos— ofrecen una base más estable para indicadores como RF-03 (desviación de importe) o RF-04 (plazo de resolución inusualmente corto) (Open Contracting Partnership, 2024b).

Riqueza para el análisis de redes. El mercado de la ingeniería pública presenta una estructura fragmentada pero interconectada: con 2.031 empresas para 3.443 contratos (ratio 1,7), la concentración del Top 1 es inferior al 1 %, lo que sugiere la existencia de nichos de concentración por organismo o subcategoría CPV sólo detectables mediante análisis de grafos. Además, el sector presenta alta propensidad a la formación de Uniones Temporales de Empresas (UTES), que enriquecen el grafo bipartito con relaciones de colaboración recurrente entre competidores (Wachs y cols., 2025; Traag, Waltman, y van Eck, 2019).

Adecuación al módulo NLP. Los pliegos de prescripciones técnicas en el ámbito de la ingeniería contienen con frecuencia criterios de adjudicación sujetos a juicio de valor —experiencia en proyectos similares, metodología propuesta, cualificación del equipo— que pueden representar hasta el 49 % de la puntuación total. Estos criterios son extraíbles mediante NLP sobre los anuncios del BOE y los PDFs en PLACE, constituyendo el corpus idóneo para detectar posibles direccionamientos técnicos (*tailored tenders*). La especificidad del vocabulario (códigos CPV de 8 dígitos como 71311000 –Consultoría en ingeniería civil– o 71356000 –Servicios técnicos–) permite segmentación precisa que reduce la varianza espúria en la comparación de importes (Portal de Contratación Pública, 2026).

Esta aproximación sectorial está alineada con la metodología del proyecto europeo DIGIWHIST (Government Transparency Institute, 2021), que segmenta el análisis por mercados específicos para garantizar la comparabilidad de los indicadores de riesgo.

2.7. Brecha identificada: posicionamiento del proyecto

Tabla 2.2: Gap identificado en la literatura que justifica ProcureWatch Analytics

Dimensión	Estado actual	ProcureWatch
Red flags en literatura	Bien documentados (Open Contracting Partnership, 2024b)	Implementado
ML para detección fraude	Demostrado en Italia, México, Kenya	Adaptado a
Análisis de redes	Probado en Portugal, Europa	Aplicado al
NLP en contratación	Survey reciente, sin prototipo	Implementado
Plataforma integrada	No existe en datos españoles	Propuesta de
Reproducibilidad	Baja en estudios existentes	100 % open-

3. Contexto y Estado del Arte

3.1. Introducción: criterios de inclusión y organización

La revisión del estado del arte cubre cinco bloques temáticos alineados con los componentes técnicos de ProcureWatch Analytics: (A) datos abiertos y estándar OCDS; (B) red flags, indicadores de riesgo y machine learning; (C) análisis de redes en contratación pública; (D) NLP y procesamiento de documentos contractuales; y (E) visualización analítica y explicabilidad. En cada bloque se identifican las referencias más relevantes de revistas indexadas (Springer Nature, Nature, IEEE, ACM) con especial atención al periodo 2019–2026.

3.2. Bloque A: Open Data de contratación pública y estándar OCDS

3.2.1. El estándar OCDS como eje de integración

El Open Contracting Data Standard (OCDS) (Open Contracting Partnership, 2024a) es el marco de referencia internacional para la estructuración de datos de contratación pública. Define más de 40 campos por contrato —desde el anuncio de licitación hasta el pago— y ha sido adoptado por más de 60 países. El *World Bank* (World Bank, 2021) ha publicado guías de implementación que detallan cómo armonizar datos nacionales con el estándar. En España, el *dataset* BOE 2014–2024 (Muñoz Plà, 2026) constituye la primera base de datos longitudinal adaptada a OCDS, con 97.000 contratos estructurados que cubren diez años de adjudicaciones.

El informe de la Open Contracting Partnership (OCP) sobre la apertura de datos en la UE (Open Contracting Partnership, 2023) señala que, si bien España ha avanzado en la publicación de datos, subsisten problemas de completitud en campos críticos (NIF del adjudicatario, importe adjudicado, fecha de adjudicación) y de inconsistencias entre lotes y expedientes. Estos hallazgos definen el punto de partida del Agente 1 (pipeline de datos) de ProcureWatch.

3.2.2. Fuentes de datos europeas y plataformas de referencia

A nivel europeo, la plataforma OpenTender.eu (Government Transparency Institute, 2024; Fazekas y Cingolani, 2025) centraliza datos de 35 jurisdicciones, con más de 19 millones de contratos e indicadores de riesgo precalculados. Para España incluye datos desde 2007 en formato JSON con campos OCDS. El portal TED (*Tenders Electronic Daily*) recoge contratos públicos de la UE por encima de umbrales comunitarios, con cobertura desde 1994.

Estas fuentes complementan el *dataset* BOE y los datos de PLACE, permitiendo comparativas de riesgo en contexto europeo alineado con la metodología DIGIWHIST (Fazekas y Cingolani, 2020).

3.3. Bloque B: Red flags, indicadores de riesgo y machine learning

3.3.1. Taxonomía de red flags en contratación pública

La Open Contracting Partnership (Open Contracting Partnership, 2024b) ha publicado la guía de referencia más actualizada sobre red flags, definiendo más de 150 indicadores organizados por fase del ciclo contractual (planificación, licitación, adjudicación, ejecución). Los principales tipos de red flags implementables sobre datos OCDS son:

- **Licitación única o restringida:** contrato con una sola oferta en procedimiento abierto, o uso sistemático del procedimiento negociado sin publicidad por encima de umbrales razonables (Open Contracting Partnership, 2016).
- **Concentración de adjudicatarios:** un proveedor acumula de forma recurrente un porcentaje elevado de contratos de un organismo (Fazekas y Cingolani, 2020).
- **Desviación de importe:** diferencia sistemáticamente alta entre importe estimado y adjudicado (Coviello y Mariniello, 2023).
- **Red flags temporales:** publicación y adjudicación en plazos muy cortos, o en periodos de menor visibilidad (Open Contracting Partnership, 2024b).
- **Procedimiento menor recurrente:** uso del contrato menor con el mismo proveedor o en importes próximos al umbral (Oficina Independiente de Regulación y

Supervisión de la Contratación, 2025).

- **Red flags combinados:** los modelos que combinan múltiples indicadores mejoran significativamente respecto al indicador único (Wachs y cols., 2025).

3.3.2. Machine learning aplicado a la detección de fraude

Coviello y Mariniello (2023) presentan el estudio empírico más sólido en contexto europeo: utilizando datos de licitaciones italianas y modelos de *random forest* con indicadores de red flags como *features*, obtienen precisiones del 70–75 % en la clasificación de contratos corruptos. Su análisis identifica la licitación única y la concentración como los indicadores con mayor poder predictivo.

Ng'ang'a (2025) proponen un framework híbrido (*Logistic Regression + Random Forest + clustering*) para datos de contratación en Kenia, demostrando que la combinación de modelos supera a los enfoques individuales. Almeida y cols. (2025) combinan machine learning y análisis de redes sociales, obteniendo mejoras adicionales cuando se incorporan métricas de grafo como *features*.

El framework PANG de Liu y cols. (2023) es específicamente relevante: aplica *pattern mining* sobre grafos de contratación para detectar subgrafos anómalos, logrando detectar tramas de adjudicaciones coordinadas no detectables con indicadores tabulares.

3.3.3. Positive-Unlabeled Learning

Un desafío metodológico central en detección de fraude contractual es la ausencia de etiquetas negativas claras: disponemos de algunos casos confirmados de irregularidad (etiquetas positivas), pero la mayoría de contratos no tienen etiqueta. El enfoque *Positive-Unlabeled Learning* (PUL) (Su y cols., 2021) aborda este problema entrenando clasificadores que aprendan a distinguir positivos de instancias no etiquetadas, sin asumir que todos los no etiquetados son negativos. Zhang y cols. (2023a) demuestran su eficacia con un enfoque contrastivo aplicado a detección de fraude.

3.3.4. Detección de anomalías no supervisada

Para el escenario en que no existen etiquetas positivas conocidas, métodos no supervisados como *Isolation Forest* (Pedregosa y cols., 2011) permiten identificar contratos atípicos basados en la distancia de sus características al resto del conjunto. Ocampo-Gutiérrez y

cols. (2019) aplican este enfoque directamente sobre datos OCDS de contratación paraguaya con resultados prometedores. El informe sistemático de Fazekas y cols. (2025) (EPJ Data Science, 2025) recoge y compara los principales enfoques de detección de fraude en la literatura reciente.

3.4. Bloque C: Análisis de redes en contratación pública

3.4.1. Grafos bipartitos empresa-organismo

El grafo bipartito empresa-organismo-contrato es la estructura natural para representar las relaciones de adjudicación: los nodos son empresas y organismos; las aristas son contratos adjudicados, con atributos de importe, tipo y fecha. Las métricas de centralidad (*degree*, *betweenness*, *eigenvector*) sobre esta estructura permiten identificar adjudicatarios con concentración atípica, organismos con comportamiento inusual, y empresas “puente” con alta intermediación en la red (Wachs y cols., 2025).

Noé y cols. (2020) demuestran en redes B2B que el análisis de flujos de pago en grafos bipartitos permite detectar suplantación de proveedores. Martins y cols. (2022) aplican este enfoque a contratación portuguesa, identificando comunidades de riesgo en el grafo de adjudicaciones. Zhang y cols. (2023b) proponen métodos de detección de fraude colectivo en grafos bipartitos sobre plataformas de comercio electrónico, directamente transferibles al contexto de contratación.

3.4.2. Detección de comunidades: algoritmos Louvain y Leiden

La detección de comunidades en el grafo empresa-organismo permite identificar grupos de empresas que licitan sistemáticamente en los mismos organismos —posible indicador de colusión— o grupos de organismos que adjudican sistemáticamente a las mismas empresas.

Traag y cols. (2019) presentan el algoritmo Leiden como mejora demostrada del Louvain: garantiza comunidades bien conectadas y reduce el tiempo de convergencia. Con una modularidad $Q \geq 0.30$ se considera que la partición de red captura estructura comunitaria real, no artefactual (Traag y cols., 2019). La implementación eficiente en memoria compartida para grafos grandes (Blondel y cols., 2024) la hace viable sobre el *dataset* completo de contratación española.

3.5. Bloque D: NLP y procesamiento de documentos de contratación

3.5.1. Named Entity Recognition en documentos legales

El procesamiento de lenguaje natural sobre documentos de contratación —pliegos de prescripciones técnicas, resoluciones de adjudicación, memorias justificativas— constituye la frontera más activa de la investigación en NLP legal. El survey de Kalamkar y cols. (2024) cubre las principales tareas (NER, clasificación, extracción de relaciones) y datasets disponibles para el dominio legal hasta 2024.

La extracción de entidades nombradas (NER) es la tarea central: identifica y clasifica organismos, empresas, importes, plazos y criterios de adjudicación en texto no estructurado. Leitner y cols. (2020) proponen enfoques de granularidad fina para documentos legales en alemán, con resultados aplicables al contexto español. El reto específico en contratación pública es la *fragmentación de entidades*: un nombre de organismo como “Consejería de Educación de la Junta de Andalucía” debe reconocerse como una sola entidad, no como cuatro entidades separadas (Honnibal, Montani, y Van Landeghem, 2020).

3.5.2. Herramientas NLP para español: spaCy y transformers

spaCy (Honnibal y cols., 2020) es el framework NLP de referencia en producción, con soporte nativo para español a través del modelo `es_core_news_lg`. Sus capacidades incluyen tokenización, POS tagging, análisis de dependencias y NER. Para documentos de contratación en español, la combinación de spaCy con *fine-tuning* sobre corpus específico del dominio permite alcanzar precisiones superiores al 80 % en identificación de entidades relevantes.

Los modelos de transformers (BERT, Legal-BETO) aportan comprensión contextual que mejora la NER en casos ambiguos. Para documentos largos (pliegos de 10–50 páginas), se aplican estrategias jerárquicas: fragmentar el documento, clasificar cada fragmento y combinar los resultados (Kalamkar y cols., 2024).

3.5.3. Web scraping: extracción estructurada de documentos administrativos

Una parte sustancial de la información relevante para la detección de riesgos en contratación pública española se encuentra disponible en los anuncios de licitación publicados en el Boletín Oficial del Estado (BOE), accesibles mediante el campo “Enlace HTML” del *dataset* longitudinal 2014–2024, así como en páginas públicas de PLACE con contenido estructurado o semiestructurado. La decisión metodológica del prototipo es sustituir el tratamiento de documentos escaneados por una estrategia de *web scraping*: se priorizan fuentes HTML trazables, reproducibles y con menor coste de limpieza, dejando los PDF no estructurados como limitación documentada o línea de trabajo futura. BeautifulSoup (Richardson, 2024) es la librería *open-source* de referencia para el parseo y extracción de información de páginas HTML y XML en Python. Proporciona una API intuitiva para navegar por el árbol DOM, localizar elementos mediante selectores CSS y extraer contenido textual de forma selectiva. Su integración con *pipelines* de NLP es directa, permitiendo la limpieza y normalización del texto extraído para su posterior procesamiento con herramientas como spaCy o su indexación en bases de datos documentales.

3.5.4. LLMs locales para análisis jurídico-administrativo

Los modelos de lenguaje locales (*Large Language Models* en local) permiten analizar documentos sin dependencia de APIs externas, preservando la confidencialidad de los datos públicos y el cumplimiento con el RGPD. Para ProcureWatch se adopta **Qwen3-8B** como modelo local principal, al combinar tamaño operativo viable, licencia permisiva, soporte multilingüe, capacidades de razonamiento e integración con herramientas (Qwen Team, 2025a, 2025b). Mistral Small 3 (Mistral AI, 2025) se mantiene como referencia comparativa para tareas de síntesis y clasificación documental.

En ProcureWatch, el LLM local tiene un rol estrictamente auxiliar: estructurar documentos, extraer entidades y generar explicaciones de casos. La decisión sobre si un contrato es sospechoso es siempre humana (European Parliament and Council, 2024).

3.6. Bloque E: Visualización analítica y explicabilidad

3.6.1. Explicabilidad en modelos de scoring de riesgo

El *AI Act* europeo (European Parliament and Council, 2024) exige especial cautela en sistemas que generan puntuaciones de riesgo con posible impacto en personas, empresas o procedimientos administrativos. Aunque ProcureWatch se plantea como prototipo académico de apoyo a la revisión humana, su diseño debe incorporar principios de trazabilidad, transparencia, control humano, gestión de riesgos, robustez y documentación técnica. Los métodos SHAP y LIME (Nallakaruppan y cols., 2025) proporcionan la base técnica para la explicabilidad del *scoring*: SHAP calcula contribuciones marginales de cada *feature* al score final, mientras que LIME ofrece aproximaciones locales interpretables.

3.6.2. Visualización de grafos interactivos

Para la visualización del grafo empresa-organismo en front-end web, el benchmarking de 2026 (PkgPulse, 2026) posiciona Sigma.js como la mejor opción para grafos grandes (>10.000 nodos) gracias a su motor WebGL, y Cytoscape.js para grafos médios con necesidades de análisis interactivo. PyVis (*vis-network* en Python) se emplea para prototipado rápido integrado en Streamlit.

3.6.3. Dashboards de riesgo

El diseño del panel de riesgo de ProcureWatch sigue los principios de jerarquía de información y flujo de revisión descritos por Ivalua (2024): priorizar el ranking de casos por nivel de riesgo, facilitar la navegación desde el caso general al detalle del contrato, e incorporar la explicación de los indicadores activados. El objetivo de usabilidad SUS ≥ 68 corresponde al nivel “aceptable” de la escala de Brooke (1996).

3.7. Conclusiones del estado del arte y justificación del proyecto

El análisis de la literatura permite extraer cuatro conclusiones que justifican directamente la propuesta:

1. **Datos de alta calidad disponibles, sin explotación sistemática.** Existen datos

abiertos de alta calidad sobre contratación pública española (BOE, PLACE), pero no hay herramientas open-source que los integren y analicen de forma sistemática con un enfoque de red flags y análisis de redes (Muñoz Plà, 2026; Open Contracting Partnership, 2023).

2. **Eficacia demostrada de métodos combinados.** La literatura demuestra consistentemente que los modelos que combinan indicadores de red flags con análisis de redes mejoran la detección respecto a indicadores aislados, pero esos modelos rara vez se implementan sobre datos españoles con herramientas reproducibles (Wachs y cols., 2025; Coviello y Mariniello, 2023; Fazekas y Cingolani, 2020).
3. **NLP como dimensión infraexplorada.** El procesamiento de documentos contractuales (pliegos, resoluciones) mediante NLP es una dimensión apenas explorada en la literatura sobre detección de fraude, a pesar de que contiene información cualitativa clave (Kalamkar y cols., 2024).
4. **Ausencia de prototipo integrado local.** No existe un prototipo open-source, local y evaluable que combine pipeline OCDS, análisis de redes, NLP documental y visualización explicable sobre contratación pública española. ProcureWatch Analytics propone cerrar exactamente esta brecha.

4. Objetivos

4.1. Objetivo General

Diseñar, desarrollar y evaluar **ProcureWatch Analytics**, una plataforma analítica multiagente que, a partir de datos abiertos de contratación pública española (BOE 2014–2024 y PLACE) y europea, detecte, cuantifique y visualice patrones de riesgo e indicadores de red flags en licitaciones, adjudicaciones y empresas adjudicatarias del dominio CPV 71, mediante análisis de datos masivos, análisis de redes societarias, NLP documental y modelos de scoring de anomalías, generando fichas de riesgo explicables que apoyen la priorización de casos para revisión por organismos de control.

4.2. Objetivos Específicos

OE1 — Análisis del dominio y las fuentes de datos

Estudiar exhaustivamente el ciclo de contratación pública española y la estructura y calidad de los datos disponibles en PLACE y el *dataset* BOE 2014–2024 según estándar OCDS, enfocando el análisis en contratos de servicios y en el dominio CPV 71, e identificando las variables más relevantes para la detección de red flags.

Métrica: Documento de análisis exploratorio con completitud, coherencia temporal y distribución de variables; matriz de relevancia: campos OCDS → indicadores de red flags; mínimo 3 fuentes complementarias identificadas.

OE2 — Diseño del modelo de datos analítico

Definir e implementar un esquema de datos integrado y armonizado con el estándar OCDS que unifique información de contratos, licitaciones, adjudicatarios, órganos contratantes y relaciones societarias para el dominio CPV 71.

Métrica: Modelo E/R documentado en PostgreSQL con mínimo 6 entidades; grafo empresa-organismo-contrato en Neo4j; completitud OCDS críticos ≥ 85 %.

OE3 — Construcción del *pipeline* de datos

Implementar un *pipeline* reproducible de descarga, limpieza, normalización, enriquecimiento y carga de datos OCDS, con validación automática de calidad y trazabilidad de fuentes.

Métrica: Pipeline ejecutable en Python + Pandas + DuckDB; completitud OCDS > 90 %; coherencia temporal > 98 %; tiempo de ejecución < 2 h.

OE4 — Desarrollo del motor de red flags

Diseñar e implementar mínimo 15 indicadores de red flags basados en literatura (Open Contracting Partnership, 2024b; Fazekas y Cingolani, 2020), complementados con Isolation Forest y Positive-Unlabeled Learning para scoring de riesgo por contrato y por adjudicatario.

Métrica: Mínimo 15 indicadores (RF-01 a RF-15) documentados con umbral y lógica; precisión > 70 % en casos con ground truth parcial; comparativa de tres enfoques documentada.

OE5 — Módulo de análisis de redes

Construir y analizar el grafo bipartito empresa-organismo-contrato para detectar comunidades (Leiden), patrones de centralidad atípicos y posibles conexiones societarias relevantes en el dominio CPV 71.

Métrica: Grafo con mínimo 2.031 nodos empresa y 394 organismos CPV 71; modularidad $Q > 0,30$; mínimo 5 patrones de concentración atípica; correlación red-flags vs centralidad ≥ 0.45 .

OE6 — Módulo NLP y enriquecimiento documental

Implementar un sistema de extracción de información estructurada sobre anuncios de licitación del BOE y pliegos alojados en PLACE para el dominio CPV 71, mediante *web scraping* (BeautifulSoup), NER en español (spaCy) y generación de fichas explicativas con LLM local (Qwen3-8B). **Métrica:** Corpus procesado de mínimo 500 anuncios del BOE correspondientes a contratos adjudicados del CPV 71; extracción exitosa de criterios de adjudicación y certificaciones en > 70 % de los casos; ficha explicativa generada con claridad $\geq 3.5/5$ (Likert).

OE7 — Desarrollo del *front-end* analítico

Construir una interfaz web interactiva (Streamlit + Sigma.js + Plotly) con grafo de relaciones, panel de indicadores de riesgo, *timeline* de evolución temporal y ficha explicativa de caso generada con LLM local (Qwen3-8B).

Métrica: SUS > 68; tiempo medio para documentar un caso de riesgo < 5 min; ficha explicativa con claridad $\geq 3.5/5$ (Likert).

OE8 — Evaluación integral del sistema

Validar el prototipo con métricas cuantitativas de calidad del *pipeline*, precisión del motor de red flags, modularidad del grafo, calidad de la extracción de criterios contractuales (precisión/cobertura) y usabilidad, analizando cualitativamente mínimo 10 casos de riesgo en el dominio CPV 71.

Métrica: Informe de evaluación completo; fichas de 10 casos analizados; documento de limitaciones y *roadmap* de mejora.

5. Marco Normativo

El diseño de ProcureWatch Analytics debe tener en cuenta el marco normativo relevante en España y la Unión Europea:

Ley 9/2017 de Contratos del Sector Público (LCSP) (Jefatura del Estado, 2017)

— Marco regulatorio fundamental de la contratación pública en España. Define tipos de contratos, procedimientos, umbrales de publicidad y obligaciones de transparencia.

Directiva UE 2014/24/EU (European Parliament and Council, 2014) — Directiva eu-

ropea sobre contratación pública que armoniza los procedimientos en la UE y establece los principios de concurrencia y transparencia.

Ley 19/2013 de transparencia (Jefatura del Estado, 2013) — Marco de reutilización

de información pública española. Define qué información es de acceso libre y sus condiciones de reutilización.

RGPD y LOPDGDD — Los datos de contratación incluyen información sobre perso-

nas físicas (administradores, representantes). El sistema garantiza que el análisis se realiza sobre datos publicados en el marco de obligaciones de transparencia.

Reglamento de IA de la UE (AI Act, 2024) (European Parliament and Council, 2024)

— ProcureWatch genera puntuaciones de riesgo para priorizar revisión humana. Aunque el prototipo no adopta decisiones administrativas ni declara fraude, se diseña bajo principios propios de sistemas sensibles: gestión de riesgos, documentación técnica, transparencia, supervisión humana, exactitud, robustez y ciberseguridad.

5.1. Implicaciones del AI Act sobre el scoring de riesgo

El AI Act exige que los sistemas de IA con impacto potencial en derechos, acceso a servicios o decisiones institucionales incorporen controles proporcionales al riesgo. En ProcureWatch, el elemento más sensible no es el uso de Qwen3-8B para redactar fichas, sino el *score* de riesgo que ordena contratos, organismos o adjudicatarios para revisión. Por ello, el diseño adopta las siguientes salvaguardas:

1. **Finalidad limitada.** El score solo prioriza revisión analítica; no determina fraude, sanción, exclusión ni responsabilidad jurídica.
2. **Supervisión humana.** Toda interpretación de riesgo requiere revisión por una persona. El dashboard debe mostrar advertencias claras sobre el carácter indiciario del resultado.
3. **Explicabilidad individual.** Cada puntuación debe mostrar red flags activadas, valores observados, umbrales, pesos y evidencias de apoyo.
4. **Trazabilidad.** Cada ejecución conserva versión de datos, reglas, modelos, prompts, fecha de cálculo y fuentes recuperadas.
5. **Control de sesgos y calidad.** Los resultados se acompañan de métricas de completitud, nulos, cobertura temporal y limitaciones por fuente.
6. **Separación entre modelo analítico y LLM.** Qwen3-8B no calcula el score ni decide el nivel de riesgo; solo redacta explicaciones a partir de evidencias estructuradas.
7. **Minimización de datos.** El sistema usa datos publicados por obligaciones de transparencia y evita incorporar datos personales no necesarios para el análisis contractual.

Estas medidas permiten defender el prototipo como herramienta académica de apoyo a auditoría, alineada con los principios de IA confiable y con la necesidad de evitar automatismos perjudiciales en la evaluación de empresas o contratos.

6. Arquitectura Técnica e Implementación del Prototipo

6.1. Visión general

Para la entrega del 20 de mayo de 2026, ProcureWatch Analytics se presenta como un **prototipo funcional avanzado**: no se formula como un producto cerrado ni como una herramienta de decisión administrativa, sino como una arquitectura implementable y parcialmente materializable que fija los componentes, flujos, agentes, datos, criterios de trazabilidad y decisiones tecnológicas necesarias para la fase de desarrollo. Esta formulación permite defender el valor técnico del sistema sin afirmar una madurez productiva que todavía no corresponde al calendario del TFM.

El prototipo transforma datos abiertos de contratación pública en indicadores explicables de riesgo. La arquitectura separa cuatro responsabilidades analíticas, alineadas con la *Propuesta Técnica SASM*: (1) *pipeline* de datos y normalización OCDS; (2) red flags y *scoring*; (3) análisis de redes y comunidades; y (4) *web scraping*, NLP y recuperación documental. Estas responsabilidades se implementan como agentes coordinados mediante LangGraph y apoyados por LangChain para la integración RAG con Qdrant, Ollama y el modelo local Qwen3-8B.

El diseño evita que el sistema emita conclusiones jurídicas automáticas. El resultado principal es un *score* de riesgo trazable, acompañado de red flags activadas, evidencias documentales y relaciones de red. Por tanto, la plataforma se concibe como una herramienta de priorización analítica para revisión humana, no como un mecanismo de declaración de fraude.

6.2. Stack tecnológico definitivo

La selección tecnológica prioriza cuatro criterios: ejecución local, reproducibilidad académica, ecosistema abierto y adecuación al problema de contratación pública. La Tabla 6.1 resume las decisiones definitivas para la entrega del 20 de mayo.




Figura 6.1: Arquitectura funcional avanzada de ProcureWatch Analytics para la entrega del 20 de mayo de 2026.

Tabla 6.1: Stack tecnológico definitivo de ProcureWatch Analytics

Capa	Tecnología elegida	Justificación
Lenguaje principal	Python	Ecosistema maduro para ciencia de datos, NLP, aprendizaje automático, grafos y automatización de pipelines.
Procesamiento tabular	pandas, DuckDB y Polars (DuckDB Foundation, 2025; Polars, 2025)	pandas garantiza compatibilidad con el ecosistema; DuckDB permite SQL analítico sobre Parquet sin servidor; Polars acelera transformaciones sobre datasets de mayor volumen.
Persistencia relacional	PostgreSQL (PostgreSQL Global Development Group, 2025)	Base relacional robusta para contratos, adjudicatarios, organismos, indicadores, scores y trazabilidad de ejecuciones.
Grafo analítico	Neo4j Community y NetworkX (Neo4j, 2025; Hagberg, Schult, y Swart, 2008)	Neo4j facilita consulta y exploración del grafo; NetworkX permite reproducir métricas y experimentos en scripts Python.

Capa	Tecnología elegida	Justificación
Motor de red flags	Python, scikit-learn, Isolation Forest y reglas OCDS (Pedregosa y cols., 2011; Open Contracting Partnership, 2024b)	Permite combinar reglas explícitas, variables de red y detección no supervisada de anomalías.
Web scraping y parsing documental	BeautifulSoup y spaCy (Richardson, 2024; Honnibal y cols., 2020)	Extraen información desde anuncios HTML, páginas públicas y contenido textual estructurado, con menor complejidad operativa que el tratamiento de documentos escaneados.
NLP clásico	spaCy (Honnibal y cols., 2020)	Adecuado para tokenización, NER, normalización lingüística y reglas de extracción en español.
Embeddings	BGE-M3 (BAAI, 2024)	Modelo multilingüe adecuado para recuperación semántica sobre documentos en español y terminología técnica.
Vector store	Qdrant (Qdrant, 2025)	Base vectorial local para indexar fragmentos documentales y recuperar contexto por contrato o adjudicatario.
LLM local	Qwen3-8B vía Ollama (Qwen Team, 2025a, 2025b; Ollama, 2025)	Modelo de 8.2B parámetros, licencia Apache-2.0, soporte multilingüe, contexto amplio y capacidades de razonamiento/uso de herramientas. Se adopta para generación de fichas explicables, no para decidir fraude.
Orquestación multi-agente	LangGraph y LangChain (LangChain AI, 2024, 2025)	LangGraph modela agentes como nodos de un grafo de estados; LangChain integra Ollama, Qdrant, recuperación documental, prompts versionados y cadenas RAG.
API de servicio	FastAPI (FastAPI, 2025)	Expone consultas analíticas, rankings y fichas de caso mediante endpoints reproducibles y documentación OpenAPI.
Evaluación RAG	RAGAS (Ragas contributors, 2025)	Permite medir fidelidad, relevancia de contexto y calidad de respuestas generadas sobre evidencias recuperadas.

Capa	Tecnología elegida	Justificación
Dashboard	Streamlit, Plotly, Sigma.js y PyVis (Snowflake Inc., 2025; Plotly Technologies Inc., 2025; Sigma.js contributors, 2025; PyVis contributors, 2025)	Streamlit acelera el prototipo; Plotly cubre visualizaciones temporales y tabulares; Sigma.js/PyVis permiten grafos interactivos.
Reproducibilidad	Docker Compose, Git y scripts parametrizados (Docker Inc., 2025)	Facilitan ejecución local, versionado, trazabilidad de resultados y defensa técnica del prototipo.

La decisión de usar **Qwen3-8B** responde a una restricción práctica: el TFM requiere un modelo local suficientemente capaz para explicar casos y sintetizar contexto documental, pero no debe depender de APIs externas ni de infraestructura de entrenamiento intensivo. Según la ficha oficial del modelo, Qwen3-8B es un modelo causal de 8.2B parámetros con soporte multilingüe, contexto nativo de 32.768 tokens y licencia Apache-2.0 (Qwen Team, 2025a). En ProcureWatch se ejecutará mediante **Ollama**, lo que simplifica la instalación local, permite reproducir experimentos, reduce la exposición de documentos a servicios externos y facilita una defensa técnica coherente con el RGPD y el AI Act.

6.3. Justificación del uso de IA y LLM

El uso de IA en ProcureWatch no se justifica por sustituir el juicio experto, sino por resolver dos problemas técnicos que no se abordan adecuadamente con consultas relacionadas simples. En primer lugar, la contratación pública combina variables estructuradas con texto administrativo heterogéneo: anuncios, pliegos, resoluciones, memorias justificativas y criterios de adjudicación. En segundo lugar, la detección temprana de riesgo requiere relacionar señales tabulares, patrones de red y evidencia documental de forma explicable.

Por ello, el prototipo adopta un enfoque de IA **híbrido y controlado**. Las reglas OCDS, los modelos estadísticos y las métricas de red calculan variables verificables; Qwen3-8B se reserva para tareas lingüísticas: extracción asistida de información, resumen de documentos, generación de fichas explicativas y reformulación de evidencias recuperadas. Esta separación permite aprovechar capacidades de NLP y RAG sin convertir al LLM en decisor del nivel de riesgo.

La elección de un LLM local vía Ollama aporta tres ventajas específicas al TFM: (a) reproducibilidad, porque el modelo y sus parámetros pueden versionarse; (b) privacidad operativa, porque los documentos analizados no se envían a APIs externas; y (c) trazabilidad, porque cada ficha debe vincularse a indicadores calculados y fragmentos documentales recuperados. Esta arquitectura es coherente con el principio *human-in-the-loop*: el sistema prioriza y explica, pero la evaluación final corresponde siempre a una persona.

6.4. Pipeline de datos

El *pipeline* de datos convierte fuentes heterogéneas en un modelo analítico común. La fuente principal es el *dataset* longitudinal BOE 2014–2024 en formato OCDS (Muñoz Plà, 2026); PLACE y OpenTender actúan como fuentes complementarias para contrastar variables, recuperar documentos y comparar indicadores europeos.

6.4.1. Fases del pipeline

1. **Ingesta de datos brutos.** Descarga o incorporación de ficheros BOE/OCDS, datos PLACE y extractos OpenTender. Cada fichero conserva ruta, fecha de descarga, URL, hash y versión.
2. **Validación inicial.** Comprobación de esquema, codificación, duplicados, tipos de datos y presencia de campos críticos: identificador de contrato, organismo, adjudicatario, importe, fecha, procedimiento y CPV.
3. **Normalización OCDS.** Transformación de campos a entidades analíticas comunes: contrato, licitación, adjudicación, organización, proveedor, lote, documento y procedimiento.
4. **Filtrado del dominio CPV 71.** Selección de servicios de arquitectura, ingeniería e inspección para reducir heterogeneidad sectorial y mejorar comparabilidad de importes, plazos y criterios técnicos.
5. **Enriquecimiento.** Derivación de variables como duración del procedimiento, desviación de importe, recurrencia proveedor-organismo, importe acumulado, año de adjudicación, subfamilia CPV y presencia documental.

6. **Perfilado de calidad.** Generación automática de métricas de completitud, coherencia temporal, nulos, duplicados, distribución de importes y cobertura por organismo.
7. **Carga analítica.** Persistencia en PostgreSQL para consultas tabulares, Neo4j/NetworkX para el grafo y Qdrant para fragmentos documentales indexados.

6.4.2. Modelo de datos analítico

El modelo relacional se centra en entidades estables y trazables. La Tabla 6.2 resume el esquema lógico inicial, alineado con el esquema OCDS adaptado de la propuesta técnica.

Tabla 6.2: Modelo de datos analítico propuesto

Entidad	Clave principal	Campos relevantes
Contrato	<code>contract_id</code>	objeto, CPV, procedimiento, importe estimado, importe adjudicado, fechas, fuente, estado.
Organismo	<code>buyer_id</code>	nombre normalizado, tipo de administración, territorio, número de contratos, importe agregado.
Adjudicatario	<code>suppliers_id</code>	nombre normalizado, NIF cuando exista, forma jurídica, contratos ganados, importe acumulado.
Adjudicación	<code>award_id</code>	contrato, adjudicatario, importe, fecha, número de ofertas, lotes y relación con licitación.
Documento	<code>document_id</code>	URL, tipo documental, texto extraído, hash, contrato asociado y estado de scraping/parsing.
Red flag	<code>flag_id</code>	contrato, indicador, valor observado, umbral, severidad, justificación y versión de regla.
Score	<code>score_id</code>	score total, nivel de riesgo, pesos, fecha de cálculo, modelo/reglas y explicación.

6.5. Motor de red flags y scoring

El motor de red flags transforma variables observables en indicadores de riesgo. Cada indicador se define mediante: nombre, motivación, campos de entrada, regla de cálculo, umbral, severidad, limitaciones y referencia bibliográfica. Esta estructura permite auditar por qué un contrato recibe una puntuación concreta.

La primera versión prioriza indicadores implementables con los campos BOE/OCDS, variables derivadas y evidencia documental:

1. **RF-01 Licitación con baja concurrencia:** contratos con una sola oferta o información equivalente cuando el dato esté disponible.
2. **RF-02 Procedimiento restrictivo o excepcional:** uso de procedimientos negociados, menores o sin publicidad en patrones recurrentes.
3. **RF-03 Desviación de importe:** diferencia atípica entre importe estimado y adjudicado, comparada con contratos similares del CPV 71.
4. **RF-04 Plazo anómalo:** intervalo inusualmente corto entre publicación, adjudicación y formalización.
5. **RF-05 Concentración proveedor-organismo:** porcentaje elevado de contratos o importe adjudicado a un mismo proveedor por un organismo.
6. **RF-06 Recurrencia temporal:** adjudicaciones repetidas al mismo proveedor en ventanas temporales cercanas.
7. **RF-07 Fragmentación potencial:** contratos similares, importes cercanos a umbrales y proximidad temporal dentro del mismo organismo.
8. **RF-08 Riesgo de red:** centralidad, pertenencia a comunidades densas o rol de puente en el grafo empresa-organismo.

El *score* compuesto se plantea como **híbrido**, pero no opaco. La base de la puntuación procede de reglas explícitas y ponderadas; las variables de red enriquecen el contexto; los modelos no supervisados, como Isolation Forest, se usan para comparar anomalías cuando no existen etiquetas fiables; y el LLM genera explicaciones a partir de evidencias ya calculadas o recuperadas. La puntuación final se expresa en una escala 0–100 y se

traduce en niveles bajo, medio, alto o crítico, siempre acompañada de los factores que la han producido.

$$Score = w_r R + w_g G + w_d D + w_a A \quad (6.1)$$

Donde R representa red flags tabulares, G variables de grafo, D evidencia documental estructurada y A anomalías estadísticas. Los pesos w deben quedar versionados y justificados. Qwen3-8B no modifica esos pesos ni decide el score; su función es redactar una explicación controlada del resultado, citando indicadores y fragmentos recuperados.

6.6. Grafo de contratación

El grafo representa tres tipos de nodos: organismos contratantes, adjudicatarios y contratos. Las aristas conectan organismos con contratos publicados y contratos con adjudicatarios. En escenarios donde existan UTEs, adjudicatarios múltiples o datos societarios abiertos, el grafo incorpora relaciones adicionales entre empresas que participan conjuntamente o comparten vínculos relevantes.

Las métricas previstas son:

- grado y grado ponderado por importe;
- centralidad de intermediación para detectar actores puente;
- centralidad de autovector o PageRank para estimar influencia estructural;
- detección de comunidades con Leiden o Louvain;
- concentración por organismo, proveedor y subfamilia CPV.

Estas variables no se interpretan como evidencia de irregularidad por sí solas. Su valor analítico aparece cuando coinciden con red flags tabulares o documentales: por ejemplo, una comunidad densa de adjudicatarios recurrentes en un conjunto reducido de organismos, combinada con baja concurrencia y plazos atípicos.

6.7. Módulo documental, embeddings y RAG

El módulo documental incorpora contexto cualitativo procedente de anuncios BOE, páginas públicas de PLACE, resoluciones y memorias justificativas accesibles como contenido HTML o texto reutilizable. Para esta versión del prototipo se prioriza *web scraping*

con BeautifulSoup frente al tratamiento de documentos escaneados: el objetivo es capturar campos, criterios técnicos, certificaciones, solvencia requerida y ponderaciones de adjudicación desde fuentes trazables y repetibles. Posteriormente, spaCy extrae entidades y patrones básicos: organismos, empresas, importes, fechas, criterios técnicos, certificaciones, solvencia requerida y ponderaciones de adjudicación.

El flujo RAG se limita a explicar casos, no a decidir el nivel de riesgo:

1. fragmentación de documentos por contrato y sección;
2. generación de embeddings con BGE-M3;
3. indexación en Qdrant con metadatos de contrato, fuente y página;
4. recuperación de fragmentos relevantes para cada contrato priorizado;
5. generación de ficha explicativa con Qwen3-8B;
6. validación de que cada afirmación de la ficha está respaldada por fragmentos recuperados.

La ficha explicativa tendrá formato estructurado: resumen del contrato, indicadores activados, evidencia tabular, evidencia de red, evidencia documental, limitaciones y recomendación de revisión humana.

6.8. Implementación multiagente

La arquitectura multiagente se implementa con LangGraph porque permite definir un flujo de estados explícito y auditable. LangChain actúa como capa de integración para herramientas, prompts, recuperadores y llamadas a Ollama. La decisión clave para esta entrega es mantener **cuatro agentes especializados**, exactamente alineados con la propuesta técnica, y tratar el orquestador como infraestructura de ejecución, no como un quinto agente funcional.

Tabla 6.3: Agentes previstos en ProcureWatch Analytics

Agente	Responsabilidad	Salida
Agente 1: Pipeline de Datos y Normalización OCDS	Descarga, limpia, valida y normaliza fuentes BOE/OCDS, PLACE y OpenTender; detecta inconsistencias de importes, fechas, duplicados y NIF; prepara tablas analíticas y artefactos de carga.	Dataset normalizado, perfil de calidad, hashes de fuentes, tablas PostgreSQL y ficheros Parquet/DuckDB.
Agente 2: Red Flags y Scoring	Calcula indicadores de riesgo por contrato y adjudicatario; combina reglas OCDS, concentración, recurrencia, desviaciones, variables de red y modelos no supervisados; genera rankings para revisión humana.	Red flags activadas, score 0–100, nivel de riesgo, justificación por indicador y ranking priorizado.
Agente 3: Análisis de Redes y Comunidades	Construye y analiza el grafo empresa-organismo-contrato; calcula centralidad, clustering, comunidades Leiden/Louvain, patrones de concentración y posibles relaciones societarias cuando existan fuentes abiertas.	Métricas de red, comunidades, subgrafos de caso, entidades puente y alertas de concentración relacional.
Agente 4: Web Scraping, NLP y Recuperación Documental	Procesa anuncios, páginas públicas y documentos textuales reutilizables; aplica BeautifulSoup, spaCy, embeddings BGE-M3 y Qdrant; recupera contexto y genera fichas explicativas con Qwen3-8B mediante Ollama.	Entidades extraídas, corpus indexado, fragmentos recuperados, respuesta RAG citada y ficha explicativa de caso.

El estado compartido de LangGraph contiene, como mínimo, identificador de ejecución, versión del dataset, contratos seleccionados, variables normalizadas, red flags, métricas de red, fragmentos documentales, prompts versionados, salida JSON de cada agente y errores detectados. Las transiciones se definen de forma secuencial y auditable: el Agente 1 prepara datos; los Agentes 2 y 3 calculan riesgo tabular y relacional; el Agente 4 recupera evidencias y genera explicaciones; finalmente, el sistema consolida la ficha de caso para el dashboard.




Figura 6.2: Flujo de trazabilidad desde la fuente hasta la ficha explicativa.

6.9. Interfaz analítica

El dashboard se diseña para una tarea concreta: localizar contratos de mayor riesgo, entender por qué han sido priorizados y revisar la evidencia asociada. La primera versión incluirá:

- KPIs generales: número de contratos, importe total, organismos, adjudicatarios y distribución de riesgo;
- filtros por año, CPV, organismo, adjudicatario, procedimiento y nivel de riesgo;
- ranking de contratos y adjudicatarios por score;
- vista de detalle de contrato con red flags activadas y valores observados;
- grafo interactivo de relaciones organismo-adjudicatario-contrato;
- ficha explicativa generada con evidencias tabulares, de red y documentales.

La interfaz no debe mostrar el score como una verdad absoluta. Debe presentarlo como una prioridad de revisión, acompañada de factores explicativos y limitaciones de datos.

6.10. Trazabilidad, calidad y reproducibilidad

La trazabilidad se considera un requisito de diseño. Cada resultado debe poder reconstruirse desde los datos de origen. Para ello, el prototipo registrará: versión del dataset, hash de ficheros, fecha de ejecución, versión de reglas, pesos de scoring, modelo LLM utilizado, prompt versionado y fragmentos documentales recuperados.

Los criterios mínimos de calidad son:

- completitud de campos OCDS críticos superior al 90 %;
- coherencia temporal superior al 98 %;
- documentación de nulos y campos no disponibles;
- explicación individual de cada red flag activada;
- fichas generadas solo con evidencias recuperadas y citables;
- separación entre hechos observados, inferencias analíticas y limitaciones.

6.11. Entregable técnico del 20 de mayo

Para la entrega del 20 de mayo de 2026, este capítulo deja cerradas las decisiones de diseño necesarias para presentar ProcureWatch como prototipo funcional avanzado: arquitectura general, *stack* definitivo, selección de Qwen3-8B vía Ollama, flujo de datos, cuatro agentes LangGraph/LangChain y criterios de trazabilidad. La implementación posterior deberá materializar estas decisiones en scripts, servicios, pruebas y dashboard.

Los elementos que quedan fijados son:

1. uso de BOE 2014–2024 como fuente principal y PLACE/OpenTender como fuentes complementarias;
2. adopción de Qwen3-8B vía Ollama como LLM local para NLP, RAG y fichas explicativas;
3. *scoring* híbrido con base de reglas trazables, variables de red, anomalías estadísticas y explicación asistida por LLM;
4. almacenamiento relacional en PostgreSQL, grafo en Neo4j/NetworkX e índice documental en Qdrant;
5. arquitectura multiagente con cuatro agentes especializados sobre LangGraph y LangChain;
6. dashboard explicable orientado a revisión humana.

7. Conclusiones y Trabajo Futuro

[A desarrollar en la fase final del TFM]

Referencias

- Agencia Tributaria de España. (2023). *Desarticulada una trama de fraude en la contratación de obra pública en cantabria*. Descargado de https://sede.agenciatributaria.gob.es/Sede/Desarticulada_una_trama_de_fraude_en_la_contratacion.de_obra_publica.en.Cantabria.htm
- Almeida, J., y cols. (2025). Data-driven transparency: Machine learning and social network analysis for corruption detection in public procurement. *Procedia Computer Science*. Descargado de <https://www.sciencedirect.com/science/article/pii/S1877050925029722>
- BAAI. (2024). *BGE-M3: Multi-functionality, multi-linguality, multi-granularity text embeddings*. Descargado de <https://huggingface.co/BAAI/bge-m3>
- Blondel, V., y cols. (2024). Fast leiden algorithm for community detection in shared memory. En *Proceedings of the 53rd international conference on parallel processing (icpp 2024)*. ACM. Descargado de <https://dl.acm.org/doi/10.1145/3673038.3673146> doi: 10.1145/3673038.3673146
- Coviello, D., y Mariniello, M. (2023). Corruption red flags in public procurement: New evidence from Italian calls for tenders. *EPJ Data Science*, 11(1), 7. Descargado de <https://link.springer.com/article/10.1140/epjds/s13688-022-00325-x> doi: 10.1140/epjds/s13688-022-00325-x
- Docker Inc. (2025). *Docker Compose documentation*. Descargado de <https://docs.docker.com/compose/>
- DuckDB Foundation. (2025). *DuckDB documentation*. Descargado de <https://duckdb.org/docs/>
- European Parliament and Council. (2014). *Directive 2014/24/EU of the European Parliament and of the council of 26 february 2014 on public procurement*. Descargado de <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32014L0024>
- European Parliament and Council. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act)*. Descargado de <https://>

- eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32024R1689
- Falcón-Cortés, A., Aldana, A., y Larralde, H. (2021). Practices of public procurement and the risk of corrupt behavior. *arXiv preprint*. Descargado de <https://arxiv.org/abs/2108.02653>
- FastAPI. (2025). *FastAPI documentation*. Descargado de <https://fastapi.tiangolo.com/>
- Fazekas, M., y Cingolani, L. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using government contracting data. *British Journal of Political Science*, 50(1), 155–164. Descargado de https://ideas.repec.org/a/cup/bjposi/v50y2020i1p155-164_7.html doi: 10.1017/S0007123419000425
- Fazekas, M., y Cingolani, L. (2025). *Opentender: Public procurement data for transparency and accountability* (Inf. Téc.). Government Transparency Institute. Descargado de <https://www.govtransparency.eu/opentender/>
- Fazekas, M., y cols. (2025). Detection of fraud in public procurement: A systematic mapping study. *EPJ Data Science*. Descargado de <https://link.springer.com/article/10.1140/epjds/s13688-025-00569-3> doi: 10.1140/epjds/s13688-025-00569-3
- Government Transparency Institute. (2021). *DIGIWHIST: Digital whistleblowing as a tool for reporting corruption in the EU* (Inf. Téc.). European Commission, Horizon 2020. Descargado de <https://digiwhist.eu/>
- Government Transparency Institute. (2024). *Opentender.eu — european public procurement data portal*. Descargado de <https://opentender.eu/>
- Hagberg, A. A., Schult, D. A., y Swart, P. J. (2008). *NetworkX: Network analysis in python*. Descargado de <https://networkx.org/>
- Honnibal, M., Montani, I., y Van Landeghem, S. (2020). *spaCy: Industrial-strength natural language processing in python*. Descargado de <https://spacy.io/>
- Ivalua. (2024). *Procurement dashboard: Kpis, benchmarks and visual tips*. Descargado de <https://www.ivalua.com/blog/procurement-dashboard/>
- Jefatura del Estado. (2013). *Ley 19/2013, de 9 de diciembre, de transparencia, acceso a la información pública y buen gobierno*. Descargado de <https://www.boe.es/eli/es/1/2013/12/09/19> (BOE núm. 295, de 10 de diciembre de 2013)
- Jefatura del Estado. (2017). *Ley 9/2017, de 8 de noviembre, de contratos del sector público*. Descargado de <https://www.boe.es/eli/es/1/2017/11/08/9/con> (BOE

- núm. 272, de 9 de noviembre de 2017)
- Kalamkar, P., y cols. (2024). Natural language processing for the legal domain: A survey of tasks, datasets, and techniques. *arXiv preprint*. Descargado de <https://arxiv.org/pdf/2410.21306>
- LangChain AI. (2024). *LangGraph: Build stateful, multi-actor applications with llms*. Descargado de <https://github.com/langchain-ai/langgraph>
- LangChain AI. (2025). *LangChain documentation*. Descargado de <https://python.langchain.com/docs/>
- Leitner, E., y cols. (2020). Fine-grained named entity recognition in legal documents. En *Proceedings of the 17th extended semantic web conference (eswc 2020)*. Springer. Descargado de https://link.springer.com/chapter/10.1007/978-3-030-33220-4_20 doi: 10.1007/978-3-030-33220-4_20
- Liu, Y., y cols. (2023). Pattern mining for anomaly detection in graphs: Application to fraud in public procurement. *Lecture Notes in Computer Science*. Descargado de <https://arxiv.org/abs/2306.10857> doi: 10.1007/978-3-031-43427-3_5
- Martins, P., y cols. (2022). Network analysis for fraud detection in Portuguese public procurement. *ResearchGate Preprint*. Descargado de https://www.researchgate.net/publication/346484234_Network_Analysis_for_Fraud_Detection_in_Portuguese_Public_Procurement
- Ministerio de Hacienda y Función Pública. (2024). *Plataforma de contratación del sector público: datos abiertos de licitaciones* (Inf. Téc.). Gobierno de España. Descargado de https://www.hacienda.gob.es/es-ES/GobiernoAbierto/DatosAbiertos/Paginas/licitaciones_plataforma_contratacion.aspx
- Mistral AI. (2025). *Mistral small 3*. Descargado de <https://mistral.ai>
- Muñoz Plà, M. (2026). A decade of public procurement in spain: A longitudinal open dataset from the boe (2014-2024). *arXiv preprint*. Descargado de <https://arxiv.org/abs/2602.16731>
- Nallakaruppan, M. K., y cols. (2025). A perspective on explainable artificial intelligence methods: SHAP and LIME. *Advanced Intelligent Systems*. Descargado de <https://advanced.onlinelibrary.wiley.com/doi/10.1002/aisy.202400304> doi: 10.1002/aisy.202400304
- Neo4j. (2025). *Neo4j documentation*. Descargado de <https://neo4j.com/docs/>
- Ng'ang'a, K. (2025). A hybrid machine learning model for detecting and preventing corrup-

- tion in Kenya's public procurement contracts. *Machine Learning Research*, 10(2).
Descargado de <https://www.sciencepublishinggroup.com/article/10.11648/j.mlr.20251002.14> doi: 10.11648/j.mlr.20251002.14
- Noé, J., y cols. (2020). GraphSIF: Analyzing flow of payments in b2b networks for supplier impersonation detection. *Applied Network Science*, 5, 70. Descargado de <https://appliednetsci.springeropen.com/articles/10.1007/s41109-020-00283-1> doi: 10.1007/s41109-020-00283-1
- Ocampo-Gutiérrez, F., y cols. (2019). Anomaly detection in public procurements using the open contracting data standard. En *Ceur workshop proceedings* (Vol. 2369). Descargado de <https://ceur-ws.org/Vol-2369/short09.pdf>
- OECD. (2016). *Preventing corruption in public procurement*. OECD Publishing. doi: 10.1787/9789264251762-en
- Oficina Independiente de Regulación y Supervisión de la Contratación. (2025). *Informe anual de supervisión de la contratación pública (ias 2024)*. Descargado de <https://www.hacienda.gob.es/es-ES/Oirescon/Paginas/ias.aspx>
- Ollama. (2025). *Ollama: Run large language models locally*. Descargado de <https://ollama.com/>
- Open Contracting Partnership. (2016). *Red flags for integrity: Giving the green light to open data solutions* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2016/11/OCP2016-Red-flags-for-integrityshared-1.pdf>
- Open Contracting Partnership. (2023). *How open is public procurement data in the eu? 2023* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2023/06/OCP2023-EU-OpenData.pdf>
- Open Contracting Partnership. (2024a). *Open contracting data standard v1.1.5* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://standard.open-contracting.org/>
- Open Contracting Partnership. (2024b). *Red flags in public procurement: A guide to using data to detect corruption and fraud* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2024/12/OCP2024-RedFlagProcurement-1.pdf>
- Pedregosa, F., y cols. (2011). *Scikit-learn: Machine learning in python — IsolationForest*. Descargado de <https://scikit-learn.org/stable/modules/generated/sklearn>

`.ensemble.IsolationForest.html`

- PkgPulse. (2026). *Cytoscape.js vs vis-network vs sigma.js: Graph visualization comparison 2026*. Descargado de <https://www.pkgpulse.com/blog/cytoscape-vs-vis-network-vs-sigma-graph-visualization-javascript-2026>
- Plotly Technologies Inc. (2025). *Plotly python graphing library*. Descargado de <https://plotly.com/python/>
- Polars. (2025). *Polars documentation*. Descargado de <https://docs.pola.rs/>
- Portal de Contratación Pública. (2026). *Lista de códigos CPV 71x: Servicios de arquitectura, construcción, ingeniería e inspección*. Descargado de <https://www.publictendering.com/cpv-codes/lista-de-los-codigos-cpv/71x/>
- PostgreSQL Global Development Group. (2025). *PostgreSQL documentation*. Descargado de <https://www.postgresql.org/docs/>
- PyVis contributors. (2025). *PyVis: Interactive network visualizations in python*. Descargado de <https://pyvis.readthedocs.io/>
- Qdrant. (2025). *Qdrant documentation*. Descargado de <https://qdrant.tech/documentation/>
- Qwen Team. (2025a). *Qwen3-8B model card*. Descargado de <https://huggingface.co/Qwen/Qwen3-8B>
- Qwen Team. (2025b). *Qwen3 technical report. arXiv preprint*. Descargado de <https://arxiv.org/abs/2505.09388>
- Ragas contributors. (2025). *Ragas: Evaluation framework for retrieval augmented generation*. Descargado de <https://docs.ragas.io/>
- Richardson, L. (2024). *Beautiful soup documentation*. Descargado de <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>
- Sigma.js contributors. (2025). *Sigma.js: A javascript library dedicated to graph drawing*. Descargado de <https://www.sigmajavascript.org/>
- Snowflake Inc. (2025). *Streamlit documentation*. Descargado de <https://docs.streamlit.io/>
- Su, X., y cols. (2021). *Positive-unlabeled learning from imbalanced data*. En *Proceedings of the 30th international joint conference on artificial intelligence (ijcai-21)*. Descargado de <https://www.ijcai.org/proceedings/2021/412>
- Traag, V. A., Waltman, L., y van Eck, N. J. (2019). *From Louvain to Leiden: guaranteeing well-connected communities*. *Scientific Reports*, 9(1), 5233. Descargado de <https://>

www.nature.com/articles/s41598-019-41695-z doi: 10.1038/s41598-019-41695

-z

Wachs, J., Fazekas, M., y Kertész, J. (2025). A machine learning and network science approach to identifying corruption risks in public procurement. *arXiv preprint*. Descargado de <https://arxiv.org/abs/2512.19491>

World Bank. (2021). *Open contracting data standard: Implementation guide* (Inf. Téc.). World Bank Group. Descargado de <https://documents1.worldbank.org/curated/en/744551614955316901/pdf/Open-Contracting-Data-Standard.pdf>

Zhang, W., y cols. (2023a). Fraud detection via contrastive positive unlabeled learning. *IEEE Conference Publication*. Descargado de <https://ieeexplore.ieee.org/document/10020693/> doi: 10.1109/ICDM54844.2023.00001

Zhang, W., y cols. (2023b). Group-based fraud detection network on e-commerce platforms. En *Proceedings of the 29th acm sigkdd conference on knowledge discovery and data mining (kdd 2023)*. ACM. Descargado de https://cgi.cse.unsw.edu.au/~zhangw/files/2023_KDD_paper.pdf

A. Apéndice: Tipos de contrato incluidos en el análisis

El análisis se centra en las siguientes tipologías contractuales del BOE 2014–2024 y PLACE, filtradas por la división CPV 71:

Tabla A.1: Subtipos CPV 71 relevantes para ProcureWatch Analytics

Código CPV	Descripción
71000000	Servicios de arquitectura, construcción, ingeniería e inspección
71311000	Consultoría en ingeniería civil
71312000	Consultoría en ingeniería de estructuras
71313000	Consultoría en ingeniería medioambiental
71314000	Servicios de energía e ingeniería afines
71320000	Servicios de diseño técnico
71330000	Servicios varios de ingeniería
71340000	Servicios integrados de ingeniería
71350000	Servicios científicos y técnicos en ingeniería
71356000	Servicios técnicos
71500000	Servicios relacionados con la construcción
71600000	Servicios de pruebas, inspección y control
71700000	Servicios de supervisión e inspección