



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

ProcureWatch Analytics:
Plataforma Multiagente para la Detección de Patrones de Riesgo en Contratación Pública mediante Open Data, Análisis de Redes, Procesamiento de Lenguaje Natural y Modelos Locales de Inteligencia Artificial

Sebastián Alfonso Correa y Saturía María Hurtado Álvarez
Máster Universitario en Análisis y Visualización de Datos Masivos

Trabajo Fin de Estudios

presentado por: Sebastián Alfonso Correa y Saturía María Hurtado Álvarez

Dirigido por: Marlon Cárdenas Bonett

Ciudad:Madrid

Fecha: 22 de abril de 2026

Índice de Contenidos

Resumen	VI
Abstract	VII
1. Introducción	1
1.1. Motivación y justificación	1
1.2. Preguntas de investigación	2
1.3. Planteamiento del trabajo	2
1.4. Estructura del trabajo	3
2. Análisis del Contexto	4
2.1. Dimensión económica e institucional de la contratación pública en España .	4
2.2. Escala del sistema de contratación y sus implicaciones analíticas (PI-1) . . .	5
2.3. Irregularidades documentadas en contratación pública española (PI-2) . . .	5
2.3.1. Irregularidades detectables con indicadores tabulares	6
2.3.2. Irregularidades detectables mediante análisis relacional	6
2.3.3. Irregularidades detectables mediante análisis documental (NLP) . .	7
2.4. Limitaciones estructurales de los sistemas de control actuales (PI-3)	7
2.4.1. Limitaciones de escala y recursos	8
2.4.2. Limitaciones de datos e integración	8
2.4.3. Limitaciones metodológicas: carácter reactivo y ausencia de perspec- tiva relacional y documental	8
2.5. Eficacia del análisis de datos para la detección de riesgo: evidencia empírica (PI-4)	9
2.6. Dominio de análisis: CPV 71 como caso de validación metodológicamente justificado	10
2.7. Brecha identificada y posicionamiento del proyecto	11
3. Contexto y Estado del Arte	13
3.1. Organización de la revisión y criterios de inclusión	13
3.2. Bloque A: Open Data de contratación pública y estándar OCDS	13
3.2.1. El estándar OCDS como eje de integración	13

3.2.2.	El dataset BOE 2014–2024 como fuente longitudinal	14
3.2.3.	Plataformas europeas de referencia: OpenTender y TED	14
3.3.	Bloque B: Red flags, indicadores de riesgo y machine learning	14
3.3.1.	Taxonomía de red flags: estado actual	14
3.3.2.	Machine learning: de los indicadores aislados a los modelos compuestos	15
3.3.3.	Positive-Unlabeled Learning: tratamiento de la ausencia de etiquetas negativas	16
3.3.4.	Detección de anomalías no supervisada	16
3.4.	Bloque C: Análisis de redes en contratación pública	16
3.4.1.	Grafos bipartitos empresa-organismo y métricas de centralidad . . .	16
3.4.2.	Detección de comunidades: del algoritmo Louvain al Leiden	17
3.4.3.	Relaciones societarias: UTEs como enriquecimiento del grafo	18
3.5.	Bloque D: NLP y procesamiento de documentos de contratación	18
3.5.1.	El dominio legal como reto específico para el NLP	18
3.5.2.	Reconocimiento de entidades nombradas (NER) en documentos ad- ministrativos	19
3.5.3.	OCR y parseado de documentos administrativos	19
3.5.4.	Modelos de lenguaje locales para análisis jurídico-administrativo . .	19
3.5.5.	Recuperación aumentada con generación (RAG)	20
3.6.	Bloque E: Visualización analítica y explicabilidad	20
3.6.1.	Explicabilidad del scoring de riesgo: requisito legal y técnico	20
3.6.2.	Visualización del grafo empresa-organismo en <i>front-end</i> web	21
3.6.3.	Diseño de paneles de riesgo	21
3.7.	Conclusiones del estado del arte: cuatro hallazgos que justifican el proyecto	21
4.	Objetivos	23
4.1.	Objetivo general	23
4.2.	Objetivos específicos	23
5.	Marco Normativo	27
6.	Conclusiones y Trabajo Futuro	29
	Referencias	29
A.	Apéndice A: Subtipos CPV 71 incluidos en el análisis	34

B. Apéndice B: Indicadores de red flags implementados (RF-01 a RF-15) 35

Índice de Ilustraciones

Índice de Tablas

2.1. Fuentes y volumen de datos disponibles para contratación pública en España y Europa	4
2.2. Gap en la literatura y contribución de ProcureWatch Analytics	12
A.1. Subtipos CPV 71 relevantes para ProcureWatch Analytics	34
B.1. Indicadores de red flags RF-01 a RF-15	35

Resumen

La contratación pública en España moviliza anualmente entre el 12 y el 15 % del Producto Interior Bruto, sin contar los contratos menores que no exigen publicidad, y su gestión está expuesta a riesgos documentados de fraccionamiento, colusión y adjudicación dirigida. A pesar de la disponibilidad de datos abiertos en formato OCDS desde 2007, no existe actualmente ninguna plataforma open-source, reproducible y validada que combine, sobre datos españoles, indicadores de red flags, análisis de redes societarias y procesamiento de lenguaje natural sobre documentos contractuales.

Este trabajo propone **ProcureWatch Analytics**, una plataforma analítica multi-agente que cubre ese vacío. El sistema integra: un *pipeline* de adquisición e integración de datos OCDS; un motor de más de 15 indicadores de red flags con modelos de machine learning (Isolation Forest, Positive-Unlabeled Learning y Random Forest); un módulo de análisis de redes basado en el algoritmo Leiden para la detección de comunidades en el grafo bipartito empresa-organismo-contrato; un módulo NLP con OCR (Docling), reconocimiento de entidades (spaCy) y recuperación aumentada con generación (RAG híbrido sobre Qdrant); y un *front-end* analítico con scoring de riesgo explicable mediante SHAP y LIME.

El prototipo se valida sobre la división CPV 71 (Servicios de arquitectura, ingeniería e inspección), seleccionada por sus propiedades metodológicas favorables para la evaluación de los tres módulos, procesando el *dataset* longitudinal del BOE 2014–2024 (Muñoz Plà, 2026) (aprox. 97.000 contratos) y datos de la Plataforma de Contratación del Sector Público (PLACE). Los componentes se evalúan con métricas estándar: precisión de red flags ($> 70\%$), modularidad de grafos ($Q > 0,30$), calidad RAG (Faithfulness $> 0,80$) y usabilidad del panel (SUS > 68), generando fichas de riesgo explicables que apoyan la priorización de casos para revisión por organismos de control.

Palabras clave: contratación pública, red flags, detección de irregularidades, machine learning, análisis de redes, NLP, datos abiertos, CPV 71, OCDS, scoring de riesgo, plataforma multiagente, explicabilidad.

Abstract

Public procurement in Spain represents between 12 and 15 % of Gross Domestic Product annually and is systematically exposed to documented risks of contract splitting, collusion, and directed award. Despite the availability of structured open data in OCDS format since 2007, no open-source, reproducible and validated platform currently exists that combines, on Spanish data, red flag indicators, corporate network analysis and natural language processing over contracting documents.

This work proposes **ProcureWatch Analytics**, a multi-agent analytical platform that fills this gap. The system integrates: an OCDS data acquisition and integration pipeline; an engine of 15+ red flag indicators with machine learning models (Isolation Forest, Positive-Unlabeled Learning and Random Forest); a network analysis module based on the Leiden algorithm for community detection in the bipartite company-organisation-contract graph; an NLP module with OCR (Docling), named entity recognition (spaCy) and hybrid retrieval-augmented generation (RAG over Qdrant); and an analytical front-end with explainable risk scoring via SHAP and LIME.

The prototype is validated on CPV division 71 (Architecture, Engineering and Inspection Services), selected for its favourable methodological properties for evaluating all three modules, processing the longitudinal BOE 2014–2024 dataset (Muñoz Plà, 2026) (approx. 97,000 contracts) and PLACE data. Components are evaluated using standard metrics: red flag precision ($> 70\%$), graph modularity ($Q > 0,30$), RAG quality (Faithfulness $> 0,80$) and dashboard usability ($SUS > 68$), generating explainable risk reports to support case prioritisation for review by oversight bodies.

Keywords: public procurement, red flags, irregularity detection, machine learning, network analysis, NLP, open data, CPV 71, OCDS, risk scoring, multi-agent platform, explainability.

Sebastián Alfonso Correa y Saturía María Hurtado Álvarez
Máster Universitario en Análisis y Visualización de Datos Masivos

1. Introducción

1.1. Motivación y justificación

La contratación pública es uno de los mecanismos de gasto público con mayor exposición al riesgo de irregularidad. En España representa entre el 12 y el 15 % del PIB nacional (OECD, 2016) y moviliza anualmente decenas de miles de millones de euros en obras, servicios y suministros gestionados por más de 10.000 órganos de contratación activos. Esta magnitud, combinada con la fragmentación administrativa del sistema, la asimetría de información entre licitadores y organismos, y la complejidad técnica de los procedimientos, convierte la contratación pública en un ámbito especialmente propicio para la aparición de comportamientos irregulares (OECD, 2016; Open Contracting Partnership, 2024b).

Desde 2007, la legislación española obliga a publicar los contratos en formatos abiertos y reutilizables (Jefatura del Estado, 2017, 2013), lo que ha generado una infraestructura de datos sin precedentes. El reciente *dataset* longitudinal del BOE 2014–2024 (Muñoz Plà, 2026), con aproximadamente 97.000 contratos estructurados según el estándar Open Contracting Data Standard (OCDS), y los más de 200.000 procedimientos anuales publicados en la Plataforma de Contratación del Sector Público (PLACE) (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025) representan una oportunidad extraordinaria para el análisis sistemático mediante técnicas avanzadas de datos masivos.

La literatura científica internacional ha demostrado de forma consistente que los métodos de machine learning y análisis de redes mejoran significativamente la detección de irregularidades respecto a los enfoques basados únicamente en reglas explícitas o auditoría manual (Wachs, Fazekas, y Kertész, 2025; Fazekas y Cingolani, 2020; Coviello y Mariniello, 2023). Sin embargo, este conocimiento acumulado no se ha traducido en herramientas integradas, reproducibles y aplicadas al caso español. Los estudios de mayor impacto se han realizado sobre datos italianos (Coviello y Mariniello, 2023), portugueses (Martins y cols., 2022), mexicanos (Wachs y cols., 2025) o centroeuropeos (Fazekas y Cingolani, 2020), sin que exista un prototipo equivalente para España.

Esta doble brecha —disponibilidad de datos de alta calidad sin explotación sistemática, y conocimiento metodológico sin implementación local— constituye la justificación central de este trabajo.

1.2. Preguntas de investigación

A partir del análisis del contexto desarrollado en el Capítulo 2, el presente trabajo aborda cuatro preguntas de investigación:

PI-1 *¿Cuál es el volumen real de contratos publicados en PLACE y cuántos organismos participan, y qué implicaciones tiene esta escala para el diseño de sistemas de supervisión?*

PI-2 *¿Qué tipos de irregularidades en contratación pública se han documentado en España en los últimos diez años, y qué patrones de datos permiten detectarlas?*

PI-3 *¿Cuáles son las limitaciones estructurales de los sistemas actuales de auditoría y control, y qué tipos de análisis quedan fuera de su alcance?*

PI-4 *¿Qué evidencia empírica existe sobre la eficacia del análisis de datos masivos, el machine learning y el análisis de redes para detectar patrones de riesgo en contratación pública?*

1.3. Planteamiento del trabajo

Este TFM propone diseñar, desarrollar y evaluar **ProcureWatch Analytics**, una plataforma multiagente que, a partir de datos abiertos de contratación pública española, detecta y visualiza patrones de riesgo mediante cinco componentes integrados:

1. Un *pipeline* de adquisición, limpieza, normalización y enriquecimiento de datos Open Data en esquema OCDS unificado.
2. Un motor analítico de red flags con más de 15 indicadores basados en literatura y tres enfoques de machine learning: reglas explícitas, Isolation Forest y Positive-Unlabeled Learning.
3. Un módulo de análisis de redes societarias sobre el grafo bipartito empresa-organismo-contrato, con detección de comunidades mediante el algoritmo Leiden.
4. Un sistema de procesamiento de documentos contractuales (pliegos, resoluciones, memorias justificativas) mediante OCR, reconocimiento de entidades y motor RAG híbrido.

5. Un *front-end* analítico con grafo interactivo, panel de indicadores de riesgo, evolución temporal y fichas de riesgo explicables.

El prototipo se valida sobre el dominio CPV 71 (Servicios de arquitectura, ingeniería e inspección), cuya elección se fundamenta metodológicamente en la Sección 2.6. La metodología de desarrollo detallada, incluyendo fases, cronograma de 18 semanas, organización del equipo y entregables por fase, se documenta en el documento paralelo `metodologia_tfm.pdf`.

1.4. Estructura del trabajo

Capítulo 2 — Análisis del contexto. Responde a las cuatro preguntas de investigación con datos justificativos, caracteriza el dominio CPV 71 seleccionado y posiciona el proyecto frente a la brecha identificada en la literatura.

Capítulo 3 — Estado del arte. Revisión crítica de la literatura en cinco bloques temáticos: datos abiertos y OCDS; red flags, indicadores de riesgo y machine learning; análisis de redes; NLP y procesamiento documental; visualización analítica y explicabilidad.

Capítulo 4 — Objetivos. Objetivo general SMART y ocho objetivos específicos medibles y operativos, cada uno con métricas de éxito verificables.

Capítulo 5 — Marco normativo. Normativa relevante en el diseño del sistema.

Capítulos 6–8 — Desarrollo técnico, resultados, evaluación y conclusiones (a desarrollar en la fase de implementación).

2. Análisis del Contexto

2.1. Dimensión económica e institucional de la contratación pública en España

La contratación pública en España constituye uno de los instrumentos de política económica de mayor impacto directo: representa entre el 12 y el 15 % del PIB nacional (OECD, 2016) y canaliza la inversión pública en infraestructura, servicios esenciales, tecnología y asistencia técnica. Su gestión está distribuida entre más de 10.000 órganos de contratación activos que abarcan todos los niveles administrativos: la Administración General del Estado, 17 comunidades autónomas, 50 diputaciones provinciales, más de 8.000 municipios, universidades públicas y el amplio sector público institucional (Ministerio de Hacienda y Función Pública, 2024).

Esta fragmentación introduce una tensión estructural: por un lado, los principios de concurrencia, publicidad y transparencia exigen que la información sea pública y accesible; por otro, la dispersión entre cientos de plataformas y formatos heterogéneos dificulta el análisis sistemático. La Tabla 2.1 resume el volumen y la cobertura de las principales fuentes de datos disponibles.

Tabla 2.1: Fuentes y volumen de datos disponibles para contratación pública en España y Europa

Fuente / indicador	Volumen	Referencia
Licitaciones anuales PLACE (2024, sin contratos menores)	206.242	Oficina Independiente de Regulación y
Órganos de contratación activos en PLACE	>10.000	Ministerio de Hacienda y Función Púb
Contratos BOE 2014–2024 en formato OCDS	~97.000	Muñoz Plà (2026)
Contratos CPV 71 en dataset BOE	3.443	Muñoz Plà (2026)
Importe total adjudicado CPV 71	>2.179 M€	Muñoz Plà (2026)
Empresas adjudicatarias distintas CPV 71	2.031	Muñoz Plà (2026)
Contratos europeos en OpenTender	>19 millones	Government Transparency Institute (2
Indicadores de red flags documentados (OCP + DIGIWHIST)	>150	Open Contracting Partnership (2024b)

2.2. Escala del sistema de contratación y sus implicaciones analíticas (PI-1)

La Plataforma de Contratación del Sector Público (PLACSP) centraliza la publicación de licitaciones y adjudicaciones de toda la administración española, y constituye la fuente primaria de datos abiertos del sistema (Ministerio de Hacienda y Función Pública, 2024). Según los informes anuales de la Oficina Independiente de Regulación y Supervisión de la Contratación (OIReScon), en el ejercicio 2024 se registraron **206.242 licitaciones**, sin incluir contratos menores, lo que representa una parte sustancial del total de la actividad contractual gestionada en España (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025). Si se incorporan contratos menores, adjudicaciones directas y desgloses por lotes, el volumen total de registros anuales asciende a varios millones, aunque la cifra varía según el criterio de contabilización (contrato, expediente o lote) (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025).

Esta escala tiene una implicación analítica directa: ningún equipo de auditores puede revisar manualmente el conjunto de contratos. La supervisión exhaustiva requiere necesariamente herramientas automáticas de priorización de riesgos. Además, la fragmentación de los datos entre múltiples administraciones introduce heterogeneidad en formatos, campos disponibles y calidad de la información publicada (Open Contracting Partnership, 2023), lo que exige un *pipeline* de normalización robusto como condición previa a cualquier análisis comparativo.

2.3. Irregularidades documentadas en contratación pública española (PI-2)

La literatura científica y los informes de supervisión han identificado y documentado un conjunto estructurado de tipologías de irregularidad en la contratación pública española durante la última década. A efectos del presente trabajo, se distinguen dos niveles: irregularidades detectables mediante indicadores tabulares sobre datos OCDS, e irregularidades que requieren análisis relacional o documental.

2.3.1. Irregularidades detectables con indicadores tabulares

Fraccionamiento indebido de contratos. División artificial del objeto contractual para eludir los umbrales de publicidad y concurrencia establecidos por la LCSP. Es el indicador con mayor soporte empírico en la literatura sobre contratación española (Open Contracting Partnership, 2024b, 2016). En el dominio CPV 71, el fraccionamiento es especialmente frecuente en servicios de asistencia técnica continuada, donde la partición por fases temporales puede estar o no justificada.

Uso inadecuado del procedimiento negociado sin publicidad. Recurso sistemático al contrato menor o al procedimiento negociado —que no exige concurrencia de ofertas— con el mismo proveedor en importes recurrentemente próximos al umbral legal. Los informes OIReScon han documentado un incremento significativo de este tipo de irregularidades en los últimos ejercicios (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025).

Desviación sistemática entre importe estimado y adjudicado. Diferencias persistentemente elevadas entre el valor estimado de licitación y el importe real adjudicado, lo que puede indicar estimaciones deliberadamente infladas para reducir la concurrencia, o presupuestos artificialmente bajos para favorecer la adjudicación a un proveedor concreto (Coviello y Mariniello, 2023). En el dataset BOE, diferencias superiores al 20 % aparecen en el 5–8 % de los contratos.

Plazos de resolución inusualmente cortos. Publicación y adjudicación en períodos muy reducidos, o en fechas de baja visibilidad (vésperas de festivos, cierres de ejercicio presupuestario), que pueden limitar la concurrencia efectiva (Open Contracting Partnership, 2024b).

2.3.2. Irregularidades detectables mediante análisis relacional

Concentración atípica de adjudicaciones. En algunos organismos, un porcentaje superior al 60 % de los contratos adjudicados en un período se concentra en dos o tres proveedores, patrón que excede la variación esperable en mercados competitivos. Falcón-Cortés, Aldana, y Larralde (2021) demuestran que la concentración de adjudicaciones y la baja concurrencia son los indicadores con mayor poder predictivo de comportamiento irregular.

Prácticas colusorias. Empresas que licitan formalmente como competidores pero comparten administradores, domicilios sociales, estructura accionarial o participan conjuntamente en UTEs en otros procedimientos, lo que puede indicar coordinación en las ofertas (Open Contracting Partnership, 2024b). Estas relaciones sólo son detectables mediante análisis de redes societarias.

Adjudicaciones dirigidas con conflicto de interés. Un caso emblemático en España es el detectado en Cantabria en 2023 por la Agencia Tributaria: se identificaron adjudicaciones sistemáticamente dirigidas a empresas vinculadas a un funcionario responsable de los informes técnicos de valoración de las ofertas (Agencia Tributaria de España, 2023). La AEAT señaló explícitamente el cruce entre datos tributarios y contractuales como línea prioritaria de detección.

2.3.3. Irregularidades detectables mediante análisis documental (NLP)

Los pliegos de prescripciones técnicas, las memorias justificativas y las resoluciones de adjudicación contienen señales textuales que no son capturables por indicadores tabulares: criterios de adjudicación redactados con especificidad excepcional para favorecer a un proveedor concreto (*tailored tenders*), requisitos de experiencia en proyectos previos del mismo organismo que excluyen a la mayor parte del mercado, o memorias justificativas de urgencia que no se corresponden con la naturaleza del servicio. En el dominio CPV 71, la literatura estima que estos criterios subjetivos pueden representar hasta el 49 % de la puntuación total en procedimientos abiertos con múltiples criterios (Kalamkar y cols., 2024).

2.4. Limitaciones estructurales de los sistemas de control actuales (PI-3)

Los sistemas de auditoría y control de la contratación pública presentan limitaciones estructurales que justifican el desarrollo de herramientas analíticas avanzadas. Estas limitaciones se organizan en tres dimensiones:

2.4.1. Limitaciones de escala y recursos

El volumen de contratos publicados anualmente —más de 200.000 licitaciones, a las que deben sumarse los contratos menores no sujetos a publicidad obligatoria— excede ampliamente la capacidad de revisión manual de los órganos de control. La OIReScon, principal organismo de supervisión, dispone de recursos significativamente inferiores al volumen de actividad que debe supervisar (Oficina Independiente de Regulación y Supervisión de la Contratación, 2025). Esta desproporción hace que, en la práctica, la revisión se realice sobre muestras no representativas o a partir de denuncias.

2.4.2. Limitaciones de datos e integración

Los datos de contratación están distribuidos entre múltiples plataformas y niveles administrativos con formatos heterogéneos. El informe de la Open Contracting Partnership sobre apertura de datos en la UE (Open Contracting Partnership, 2023) constata que, en España, campos críticos como el NIF del adjudicatario, el importe exacto adjudicado o las fechas de los hitos contractuales presentan tasas de completitud irregulares. Esta situación impide el análisis sistemático y comparativo a escala nacional.

2.4.3. Limitaciones metodológicas: carácter reactivo y ausencia de perspectiva relacional y documental

El enfoque predominante en los sistemas de control es reactivo: actúan una vez detectada o denunciada la irregularidad, no antes (OECD, 2016). Además, los controles tradicionales presentan dos puntos ciegos específicos:

- **Ausencia de perspectiva relacional.** Los análisis tabulares no detectan comunidades de proveedores con comportamientos coordinados, ni patrones de concentración que son visibles únicamente en el grafo de relaciones empresa-organismo (Wachs y cols., 2025). En el dominio CPV 71, con 2.031 empresas y 394 organismos, la estructura del mercado sólo es observable mediante análisis de grafos.
- **Invisibilidad del contexto documental.** Los pliegos, resoluciones y memorias justificativas —que contienen señales textuales clave sobre posibles irregularidades— permanecen inaccesibles para los sistemas de control basados exclusivamente en campos estructurados (Kalamkar y cols., 2024).

2.5. Eficacia del análisis de datos para la detección de riesgo: evidencia empírica (PI-4)

La literatura científica de los últimos cinco años ofrece evidencias sólidas y replicadas sobre la eficacia del análisis de datos para la detección de irregularidades en contratación pública. Se resumen a continuación las contribuciones más relevantes:

Coviello y Mariniello (2023) presentan el estudio empírico de mayor rigor en el ámbito europeo: utilizando 4.000 procedimientos de contratación italiana con 500 adjudicaciones corruptas confirmadas judicialmente como *ground truth*, demuestran que modelos de Random Forest entrenados con indicadores de red flags —licitación única, concentración de adjudicaciones, desviación de importe— alcanzan precisiones del 70–75 % en detección de contratos corruptos. Su trabajo identifica, además, los indicadores de mayor poder predictivo individual y sus interacciones, proporcionando una base metodológica directamente transferible al contexto español.

Wachs y cols. (2025) aplican un enfoque combinado de machine learning y análisis de redes a datos de contratos públicos en México, demostrando que las métricas de red (centralidad de eigenvector, grado ponderado, coeficiente de agrupamiento) añaden poder predictivo significativo respecto a los modelos puramente tabulares. Su trabajo es especialmente relevante porque utiliza un diseño cuasiexperimental con proveedores sancionados como etiquetas positivas, análogo a la situación de datos disponibles en España.

El proyecto europeo DIGIWHIST (Fazekas y Cingolani, 2020; Government Transparency Institute, 2021) desarrolló el *Corruption Risk Index* (CRI), combinando cuatro indicadores observables —riesgo de licitación, conexiones políticas, riesgo del proveedor y riesgo del órgano contratante— y lo validó sobre datos de 35 jurisdicciones europeas. El CRI está disponible en OpenTender.eu (Government Transparency Institute, 2024; Fazekas y Cingolani, 2025) para todos los países de la UE, incluida España, y constituye el estándar de referencia para indicadores de riesgo comparables.

El *mapping study* sistemático de Fazekas y cols. (2025) (EPJ Data Science, 2025) analiza más de 150 publicaciones sobre detección de fraude en contratación pública y concluye que los modelos que combinan múltiples indicadores de red flags con métricas de red superan consistentemente en rendimiento a los enfoques de indicador único, con una mejora media del 15–20 % en AUC-ROC.

Finalmente, Muñoz Plà (2026) demuestran que el *dataset* BOE 2014–2024 presenta

una calidad y coherencia temporal suficientes para el análisis de patrones estructurales y temporales del riesgo en contratación española, reforzando la viabilidad técnica del proyecto.

2.6. Dominio de análisis: CPV 71 como caso de validación metodológicamente justificado

Tras el análisis exploratorio del *dataset* BOE 2014–2024, se ha seleccionado la **división CPV 71** (Servicios de arquitectura, construcción, ingeniería e inspección) como dominio de validación del prototipo ProcureWatch Analytics (Portal de Contratación Pública, 2026). Esta división comprende 3.443 contratos adjudicados con un importe total superior a los 2.179 millones de euros, distribuidos entre 394 organismos contratantes y 2.031 empresas adjudicatarias distintas.

La elección no se fundamenta en el volumen absoluto del dominio, sino en tres criterios metodológicos que lo convierten en el banco de pruebas óptimo para evaluar los tres módulos principales de la plataforma:

Criterio 1: Estabilidad de los indicadores de riesgo tabulares. A diferencia del CPV 45

(Obras, $n = 11,808$), los servicios de ingeniería presentan una menor incidencia de modificaciones contractuales legalmente justificadas (art. 205 LCSP). En obras, las desviaciones de importe y plazo son fenómenos frecuentes y a menudo legítimos por imprevistos técnicos o geopolíticos, lo que introduce ruido en los modelos de detección de anomalías no supervisados y eleva la tasa de falsos positivos. Los servicios de ingeniería, estructurados mayoritariamente en torno a tarifas horarias y entregables definidos, ofrecen una base más estable para los indicadores RF-03 (desviación de importe) y RF-04 (plazo de resolución inusualmente corto) (Open Contracting Partnership, 2024b). Esta propiedad es alineada con la metodología del proyecto DIGIWHIST, que segmenta el análisis por mercados específicos para garantizar la comparabilidad de los indicadores (Government Transparency Institute, 2021).

Criterio 2: Riqueza del grafo para análisis de redes. Con 2.031 empresas para 3.443 contratos (ratio 1,7 contratos/empresa) y una concentración del Top 1 inferior al 1 %, el mercado CPV 71 presenta la combinación teóricamente deseable: no tan concentrado como para que el grafo sea trivial, ni tan fragmentado como para que no existan

patrones de comunidad detectables. Además, el sector presenta una alta propensión a la formación de Uniones Temporales de Empresas (UTEs), que enriquecen el grafo bipartito empresa-organismo con relaciones de colaboración recurrente entre competidores, precisamente las más relevantes para la detección de colusión (Wachs y cols., 2025; Traag, Waltman, y van Eck, 2019).

Criterio 3: Adecuación del corpus documental al módulo NLP. Los pliegos de prescripciones técnicas en el ámbito de la ingeniería contienen con frecuencia criterios de adjudicación sujetos a juicio de valor —experiencia en proyectos similares, metodología propuesta, cualificación del equipo— que pueden representar hasta el 49 % de la puntuación total en procedimientos abiertos con múltiples criterios. Estos criterios son extraíbles mediante NLP sobre los anuncios del BOE y los PDFs en PLACE, constituyendo el corpus idóneo para detectar posibles direccionamientos técnicos (*tailored tenders*). La especificidad del vocabulario técnico (códigos CPV de 8 dígitos como 71311000 —Consultoría en ingeniería civil— o 71356000 —Servicios técnicos—) permite, además, una segmentación precisa que reduce la varianza espúria en la comparación de importes y la extracción de entidades (Portal de Contratación Pública, 2026; Kalamkar y cols., 2024).

2.7. Brecha identificada y posicionamiento del proyecto

La Tabla 2.2 sintetiza el gap identificado en la literatura que justifica el desarrollo de ProcureWatch Analytics.

De este análisis se desprende que la brecha no reside en la ausencia de conocimiento metodológico —la literatura es rica y rigurosa— sino en la ausencia de una implementación integrada, local, reproducible y evaluada sobre datos españoles. ProcureWatch Analytics propone cerrar precisamente ese vacío.

Tabla 2.2: Gap en la literatura y contribución de ProcureWatch Analytics		
Dimensión	Estado de la literatura	Contribución de este TFM
Red flags en contratación	Bien documentados y taxonomizados (Open Contracting Partnership, 2024b)	Implementación, evaluación y combinación con ML
ML para detección de fraude	Demostrado empíricamente en Italia, México, Kenia (Coviello y Mariniello, 2023; Wachs y cols., 2025; Ng’ang’a, 2025)	Adaptación y evaluación sobre datos españoles
Análisis de redes	Probado en Portugal, Europa (Martins y cols., 2022; Fazekas y Cingolani, 2020)	Aplicación sobre CPV 71 español con Leiden
NLP en contratación	Survey teórico reciente, sin prototipo (Kalamkar y cols., 2024)	Implementación sobre pliegos en español
Plataforma integrada	No existe en datos españoles	Propuesta de este TFM
Reproducibilidad	Limitada en estudios existentes	100 % open-source + Docker
Explicabilidad (AI Act)	Exigida desde 2024 (European Parliament and Council, 2024)	SHAP + LIME con trazabilidad completa

3. Contexto y Estado del Arte

3.1. Organización de la revisión y criterios de inclusión

La revisión del estado del arte cubre cinco bloques temáticos, directamente alineados con los cinco componentes técnicos de ProcureWatch Analytics: (A) datos abiertos y estándar OCDS; (B) red flags, indicadores de riesgo y machine learning; (C) análisis de redes en contratación pública; (D) NLP y procesamiento de documentos contractuales; y (E) visualización analítica y explicabilidad.

Se han priorizado publicaciones en revistas indexadas (Springer Nature, Cambridge University Press, IEEE, ACM, Wiley) y proyectos financiados por la UE (DIGIWHIST, OCP) del período 2019–2026. Se incluyen *preprints* de arXiv únicamente cuando el trabajo es ampliamente citado o representa la única fuente disponible sobre un dato específico (e.g., el dataset BOE 2014–2024 de Muñoz Plà (2026)).

3.2. Bloque A: Open Data de contratación pública y estándar OCDS

3.2.1. El estándar OCDS como eje de integración

El Open Contracting Data Standard (OCDS) (Open Contracting Partnership, 2024a) es el marco de referencia internacional para la estructuración y la interoperabilidad de datos de contratación pública. Define más de 40 campos por contrato —organizados en cinco secciones: *planning*, *tender*, *award*, *contract* y *implementation*— y ha sido adoptado por más de 60 países. El Banco Mundial (World Bank, 2021) ha publicado guías de implementación que detallan cómo armonizar fuentes nacionales heterogéneas con el estándar; sus directrices sobre identificadores de organismo y de empresa son directamente aplicables al contexto de PLACE y el BOE.

El análisis comparativo de la OCP sobre apertura de datos en la UE (Open Contracting Partnership, 2023) constata que España ha avanzado notablemente en la publicación de datos, pero subsisten problemas de completitud en campos críticos (NIF del adjudicatario, importe adjudicado exacto, fechas de hitos) y de inconsistencias entre la información publicada a nivel de expediente y a nivel de lote. Estas deficiencias definen el punto de

partida y las tareas de limpieza del Agente 1 (*pipeline* de datos) de ProcureWatch.

3.2.2. El dataset BOE 2014–2024 como fuente longitudinal

Muñoz Plà (2026) presentan el primer *dataset* longitudinal de contratación pública española en formato OCDS: aproximadamente 97.000 contratos adjudicados publicados en el BOE entre 2014 y 2024, con información sobre organismos contratantes, empresas adjudicatarias, importes, procedimientos y códigos CPV. La publicación del *dataset* como recurso abierto y reproducible es una contribución metodológica relevante: permite replicar análisis, comparar resultados entre estudios y evaluar la evolución temporal del sistema de contratación a lo largo de una década.

Para el presente trabajo, el dataset BOE 2014–2024 constituye la fuente de datos primaria del prototipo, complementada con datos en tiempo real de PLACE.

3.2.3. Plataformas europeas de referencia: OpenTender y TED

A nivel europeo, la plataforma OpenTender.eu (Government Transparency Institute, 2024; Fazekas y Cingolani, 2025) centraliza datos de 35 jurisdicciones con más de 19 millones de contratos e indicadores de riesgo precalculados, incluido el *Corruption Risk Index* (CRI) desarrollado por el proyecto DIGIWHIST (Fazekas y Cingolani, 2020). Para España, incluye datos desde 2007 en formato JSON con campos OCDS. El portal TED (*Tenders Electronic Daily*) recoge contratos que superan los umbrales comunitarios de publicidad, con cobertura desde 1994. Estas plataformas complementan el dataset BOE y permiten comparativas de riesgo en contexto europeo, lo que enriquece la validación del prototipo.

3.3. Bloque B: Red flags, indicadores de riesgo y machine learning

3.3.1. Taxonomía de red flags: estado actual

La Open Contracting Partnership (Open Contracting Partnership, 2024b) ha publicado la guía de referencia más actualizada sobre indicadores de riesgo en contratación pública. Define más de 150 red flags organizados por fase del ciclo contractual (planificación, licitación, adjudicación, ejecución), tipo de irregularidad (fraccionamiento, colusión,

conflicto de interés, modificación injustificada) y tipo de datos necesarios para su cálculo (campos OCDS, datos de empresa, datos relacionales). La taxonomía original de 2016 (Open Contracting Partnership, 2016) ha sido revisada y ampliada en 2024 incorporando la dimensión de redes societarias y el contexto de datos masivos.

Los indicadores más frecuentemente implementados en la literatura, y que constituyen el núcleo del motor de red flags de ProcureWatch, son:

1. Tasa de licitación única o restringida (RF-01).
2. Concentración relativa de adjudicaciones por organismo (RF-02).
3. Desviación porcentual entre importe estimado y adjudicado (RF-03).
4. Plazo de resolución inusualmente corto (RF-04).
5. Recurrencia del mismo proveedor en procedimientos negociados (RF-05).
6. Uso reiterado del contrato menor en importes cercanos al umbral (RF-06).

3.3.2. Machine learning: de los indicadores aislados a los modelos compuestos

El estudio de Coviello y Mariniello (2023) es el punto de referencia metodológico más sólido disponible para el contexto europeo. Utilizando datos de licitaciones italianas con 500 contratos corruptos confirmados judicialmente, demuestran que un Random Forest entrenado sobre los indicadores de la taxonomía OCP alcanza el 70–75 % de precisión, frente a un 45–50 % de los indicadores aislados. Su análisis de importancia de variables mediante Gini revela que la licitación única y la concentración de adjudicaciones son los predictores individuales más potentes, pero que sus interacciones añaden hasta un 12 % de mejora adicional en AUC-ROC.

Ng'ang'a (2025) proponen un *framework* híbrido para datos de contratación en Kenia combinando Logistic Regression, Random Forest y *clustering* no supervisado, obteniendo mejoras sobre cada modelo individual. Almeida y cols. (2025) incorporan análisis de redes sociales como capa adicional de *features*, con mejoras adicionales en AUC cuando se añaden métricas de centralidad. El *mapping study* sistemático de Fazekas y cols. (2025) confirma, sobre más de 150 publicaciones, que los modelos compuestos superan consistentemente a los enfoques de indicador único.

El framework PANG de Liu y cols. (2023) es específicamente relevante para ProcureWatch: aplica *pattern mining* sobre grafos de contratación para detectar subgrafos anómalos —conjuntos de contratos, organismos y empresas cuya estructura de relaciones es estadísticamente improbable en un mercado competitivo— logrando detectar tramas de adjudicaciones coordinadas no identificables con indicadores tabulares.

3.3.3. Positive-Unlabeled Learning: tratamiento de la ausencia de etiquetas negativas

Un desafío metodológico central en la detección de fraude contractual es la ausencia de etiquetas negativas claras. Se dispone de algunos casos confirmados de irregularidad (etiquetas positivas) y de un amplio volumen de contratos sin etiqueta, pero no es lícito asumir que todos los contratos no etiquetados son legítimos. El enfoque *Positive-Unlabeled Learning* (PUL) (Su y cols., 2021) aborda este problema entrenando clasificadores que aprendan a distinguir positivos de instancias no etiquetadas, sin penalizar como errores los positivos no identificados. Zhang y cols. (2023a) demuestran su eficacia con un enfoque contrastivo aplicado específicamente a detección de fraude financiero, con mejoras de hasta 8 puntos porcentuales en precisión sobre métodos supervisados clásicos cuando la tasa de casos etiquetados es inferior al 5 %.

3.3.4. Detección de anomalías no supervisada

Para el escenario en que no existen etiquetas positivas conocidas, métodos no supervisados como Isolation Forest (Pedregosa y cols., 2011) permiten identificar contratos atípicos en función de la distancia de sus características al resto del conjunto. Ocampo-Gutiérrez y cols. (2019) aplican este enfoque directamente sobre datos OCDS de contratación paraguaya, obteniendo resultados coherentes con el conocimiento experto sobre irregularidades conocidas. En ProcureWatch, Isolation Forest se utiliza como línea de base para comparar con los enfoques supervisados y PUL.

3.4. Bloque C: Análisis de redes en contratación pública

3.4.1. Grafos bipartitos empresa-organismo y métricas de centralidad

El grafo bipartito empresa-organismo-contrato es la estructura topológica natural para representar el sistema de adjudicaciones: los nodos son empresas y organismos; las aristas

son contratos adjudicados, con atributos de importe, tipo de procedimiento y fecha. Esta representación permite calcular métricas de centralidad que capturan propiedades del mercado no observables en tablas planas:

- **Grado ponderado por importe:** suma de los importes adjudicados por nodo, indicadora de participación económica en el mercado.
- **Centralidad de intermediación (*betweenness*):** empresas que actúan como “puentes” en la red, adjudicatarias de múltiples organismos de perfil heterogéneo, lo que puede indicar capacidad de influencia transversal.
- **Centralidad de vector propio (*eigenvector*):** empresas conectadas a organismos con alta actividad contractual, relevante para detectar relaciones preferenciales de alto valor.

Wachs y cols. (2025) demuestran que estas métricas, combinadas con indicadores de red flags, mejoran la predicción de riesgo de forma significativa y estable en diferentes contextos nacionales. Martins y cols. (2022) aplican análisis de grafos a la contratación portuguesa, identificando comunidades de riesgo cuya detección no es posible mediante indicadores tabulares.

Noé y cols. (2020) aportan evidencia desde el contexto de redes B2B: demuestran que el análisis de flujos de pago en grafos bipartitos permite detectar suplantación de proveedores con alta precisión. Zhang y cols. (2023b) extienden este enfoque a la detección de fraude colectivo en grafos bipartitos de plataformas de comercio electrónico, con métodos directamente transferibles al contexto de contratación.

3.4.2. Detección de comunidades: del algoritmo Louvain al Leiden

La detección de comunidades en el grafo empresa-organismo permite identificar grupos de empresas que licitan sistemáticamente en los mismos organismos —posible indicador de colusión o acuerdo de reparto de mercado— o grupos de organismos que adjudican recurrentemente a las mismas empresas. El indicador estándar de calidad de la partición comunitaria es la modularidad Q : valores superiores a 0,30 se consideran indicativos de estructura comunitaria real, no artefactual (Traag y cols., 2019).

Traag y cols. (2019) presentan el algoritmo Leiden como mejora demostrada del Louvain: garantiza comunidades internas bien conectadas (resolviendo un fallo estructural del

Louvain donde comunidades aparentes podían estar internamente desconectadas) y reduce el tiempo de convergencia en grafos grandes. La implementación eficiente en memoria compartida de Blondel y cols. (2024) hace viable la ejecución del Leiden sobre el grafo completo de contratación española sin necesidad de infraestructura distribuida.

3.4.3. Relaciones societarias: UTEs como enriquecimiento del grafo

En el dominio CPV 71, la alta propensión a la formación de Uniones Temporales de Empresas (UTEs) introduce un tercer tipo de nodo en el grafo: la entidad temporal formada por empresas que compiten de forma independiente en otros procedimientos. La detección de empresas que forman UTEs recurrentes con la misma composición, o que forman UTEs con empresas con las que tienen relaciones societarias previas, es un indicador de posible coordinación que complementa los indicadores tabulares. Este enriquecimiento del grafo es una aportación metodológica específica del presente trabajo.

3.5. Bloque D: NLP y procesamiento de documentos de contratación

3.5.1. El dominio legal como reto específico para el NLP

El procesamiento de documentos de contratación —pliegos de prescripciones técnicas, resoluciones de adjudicación, memorias justificativas— plantea retos específicos respecto al NLP de propósito general. El survey de Kalamkar y cols. (2024), que revisa 3.000 publicaciones sobre NLP legal publicadas hasta 2024, identifica cinco dimensiones que hacen del dominio legal un entorno singular: (1) vocabulario especializado y jerga jurídica con significados distintos a los del lenguaje general; (2) referencias cruzadas a artículos legales, procedimientos y entidades que exigen resolución de co-referencia; (3) documentos largos (10–200 páginas) con estructura jerarquizada; (4) necesidad de extraer fragmentos específicos en posiciones predecibles (artículos, cláusulas); y (5) baja disponibilidad de corpus etiquetados para entrenamiento.

En el contexto de contratación pública en español, estos retos se ven amplificados por la variabilidad de formatos entre organismos y la mezcla de texto legible por máquina (pliegos en Word o HTML) y PDFs escaneados que requieren OCR previo.

3.5.2. Reconocimiento de entidades nombradas (NER) en documentos administrativos

La tarea central del módulo NLP de ProcureWatch es el reconocimiento de entidades nombradas (NER): identificar y clasificar en texto no estructurado los organismos contratantes, empresas licitadoras, importes, plazos, criterios de adjudicación y códigos CPV. Leitner y cols. (2020) proponen enfoques de granularidad fina para NER en documentos legales, con especial atención a la fragmentación de entidades largas y a la co-referencia entre nombres completos y abreviaciones.

Para el español, el framework NLP de referencia en producción es spaCy (Honnibal, Montani, y Van Landeghem, 2020), con soporte nativo para español a través del modelo `es_core_news_lg`. Sus capacidades incluyen tokenización, POS tagging, análisis de dependencias y NER sobre 18 tipos de entidades. Para el dominio específico de contratación, se requiere *fine-tuning* adicional sobre un corpus del dominio para alcanzar las precisiones reportadas en la literatura (> 75 % en F1 para entidades críticas). Los modelos de transformers (BERT-base, Legal-BETO) aportan comprensión contextual que mejora el NER en casos ambiguos, a costa de mayor coste computacional (Kalamkar y cols., 2024).

3.5.3. OCR y parseado de documentos administrativos

Una parte sustancial de los documentos disponibles en PLACE está en formato PDF escaneado, lo que requiere OCR previo a cualquier análisis NLP. Docling (IBM Research, 2024) (IBM Research, 2024) es la herramienta open-source de referencia para parsing avanzado de documentos complejos con OCR integrado: maneja tablas, encabezados, notas al pie y layouts multícolumna, y exporta en formatos JSON y Markdown directamente compatibles con pipelines de NLP. El benchmark comparativo de 2025 (IBM Research, 2024) posiciona a Docling como la alternativa open-source con mejor relación precisión/velocidad para documentos de tipo administrativo o legal, frente a alternativas cloud-based como Amazon Textract.

3.5.4. Modelos de lenguaje locales para análisis jurídico-administrativo

Los modelos de lenguaje de gran escala (LLMs) en ejecución local permiten analizar documentos sin dependencia de APIs externas, preservando la confidencialidad de los datos y facilitando el cumplimiento con el RGPD y el AI Act. Para el español, Qwen3-7B

(Alibaba Cloud, 2024) ofrece un soporte de alta calidad con requerimientos de memoria gestionables (64 GB RAM); Mistral Small 3 (Mistral AI, 2025) es la referencia comparativa para tareas de síntesis y clasificación. En ProcureWatch, el LLM local tiene un rol estrictamente auxiliar y acotado: estructurar documentos, extraer entidades con contexto y generar explicaciones de casos. La decisión de si un contrato es sospechoso es siempre humana, en cumplimiento del artículo 14 del AI Act (European Parliament and Council, 2024).

3.5.5. Recuperación aumentada con generación (RAG)

El sistema RAG de ProcureWatch combina un recuperador de fragmentos documentales semánticamente relevantes con el LLM local para producir respuestas contextualizadas sobre un caso de riesgo: dado un contrato o adjudicatario con múltiples red flags activados, el motor recupera y sintetiza los fragmentos de pliegos y resoluciones que explican o matizan los indicadores activados (LangChain AI, 2024).

La recuperación híbrida combina dos enfoques complementarios: búsqueda densa mediante embeddings multilingües BGE-M3 (BAAI, 2024) (indexados en Qdrant) y búsqueda léxica BM25 para términos técnicos específicos de contratación (como códigos CPV o referencias a artículos de la LCSP) que no son capturados eficientemente por la búsqueda semántica. La calidad del sistema se evalúa con el framework RAGAS, con objetivos: Faithfulness > 0,80, Answer Relevancy > 0,75 y Context Recall > 0,70.

3.6. Bloque E: Visualización analítica y explicabilidad

3.6.1. Explicabilidad del scoring de riesgo: requisito legal y técnico

El Reglamento de IA de la UE (European Parliament and Council, 2024) clasifica como sistemas de **alto riesgo** aquellos que generan puntuaciones que puedan influir en decisiones sobre empresas o contratos públicos (Anexo III, sección 8). Esta clasificación implica obligaciones específicas: trazabilidad de las decisiones, documentación del sistema, evaluación de conformidad y, fundamentalmente, supervisión humana obligatoria. En consecuencia, la explicabilidad no es una característica opcional del prototipo, sino un requisito normativo.

Los métodos SHAP (*SHapley Additive exPlanations*) y LIME (*Local Interpretable Model-Agnostic Explanations*) (Nallakaruppan y cols., 2025) son los enfoques de referen-

cia para la explicabilidad de modelos de machine learning. SHAP calcula la contribución marginal exacta de cada *feature* al score de riesgo de un contrato específico, basada en la teoría de valores de Shapley; LIME construye una aproximación local lineal del modelo en el entorno del caso de interés. En ProcureWatch, SHAP se utiliza para la ficha de riesgo automática y para el panel de contribución de indicadores; LIME como validación de coherencia de las explicaciones SHAP.

3.6.2. Visualización del grafo empresa-organismo en *front-end* web

Para la visualización interactiva del grafo bipartito en el navegador, el benchmarking de 2026 (PkgPulse, 2026) posiciona a Sigma.js como la mejor opción para grafos grandes ($> 10,000$ nodos) gracias a su motor WebGL de renderizado en GPU, y a Cytoscape.js como alternativa para grafos medianos ($< 5,000$ nodos) con mayores necesidades de análisis interactivo integrado. En ProcureWatch, Sigma.js se utiliza para el grafo principal y PyVis (*vis-network* en Python) para la visualización rápida integrada en el panel Streamlit durante el prototipado.

3.6.3. Diseño de paneles de riesgo

El diseño del panel de riesgo de ProcureWatch sigue los principios de jerarquía de información y flujo de revisión documentados en la literatura de *procurement analytics* (Ivalua, 2024): (1) priorizar el ranking de casos por nivel de riesgo en la vista principal; (2) facilitar la navegación desde el caso general al detalle del contrato mediante selecciones en el grafo; (3) incorporar la explicación de los indicadores activados en la ficha del caso, sin requerir conocimiento técnico del modelo. El objetivo de usabilidad SUS > 68 corresponde al umbral “aceptable” de la escala de Brooke, validado sobre usuarios con perfil de analista técnico no experto en ML.

3.7. Conclusiones del estado del arte: cuatro hallazgos que justifican el proyecto

La revisión sistemática de la literatura permite extraer cuatro hallazgos que justifican directamente la propuesta:

1. **Datos disponibles de alta calidad, sin explotación sistemática.** El *dataset*

BOE 2014–2024 (Muñoz Plà, 2026) y los datos abiertos de PLACE (Ministerio de Hacienda y Función Pública, 2024) constituyen una base de datos de contratación de alta calidad y cobertura decenal. Sin embargo, no existe a la fecha ninguna herramienta open-source que los integre y analice con un enfoque combinado de red flags, análisis de redes y NLP.

2. **Eficacia demostrada de los métodos combinados.** La literatura demuestra consistentemente, en tres contextos europeos y latinoamericanos distintos (Coviello y Mariniello, 2023; Wachs y cols., 2025; Fazekas y Cingolani, 2020), que los modelos que combinan indicadores de red flags con métricas de red mejoran la detección de irregularidades en 15–20 puntos de AUC-ROC respecto a indicadores aislados. Esta mejora no se ha validado sobre datos españoles.
3. **NLP como dimensión infraexplotada.** A pesar de que el survey de Kalamkar y cols. (2024) documenta una madurez creciente de las técnicas, el procesamiento de documentos contractuales (pliegos, resoluciones) con NLP es prácticamente inexistente en la literatura de detección de fraude en contratación pública, a pesar de que, como se ha documentado en la Sección 2.3, contienen información cualitativa sobre el riesgo que no es capturada por los datos estructurados.
4. **Ausencia de prototipo integrado, local y evaluado.** No existe en la literatura ningún prototipo open-source que combine *pipeline* OCDS, motor de red flags con ML, análisis de redes con Leiden, módulo NLP con RAG y front-end explicable sobre datos de contratación pública española. ProcureWatch Analytics propone cubrir exactamente esta brecha.

4. Objetivos

4.1. Objetivo general

Diseñar, desarrollar y evaluar **ProcureWatch Analytics**, una plataforma analítica multiagente que, a partir de datos abiertos de contratación pública española (BOE 2014–2026 y PLACE) y del estándar OCDS, detecte, cuantifique y visualice patrones de riesgo e indicadores de red flags en licitaciones, adjudicaciones y empresas adjudicatarias del dominio CPV 71, mediante análisis de datos masivos, análisis de redes societarias, procesamiento de lenguaje natural sobre documentos contractuales y modelos de scoring de anomalías con explicabilidad verificable, generando fichas de riesgo interpretables que apoyen la priorización de casos para revisión por organismos de control, en cumplimiento del marco normativo vigente.

4.2. Objetivos específicos

OE1 — Análisis del dominio y las fuentes de datos

Descripción: Estudiar exhaustivamente el ciclo de contratación pública española, la estructura y calidad de los datos disponibles en PLACE y en el *dataset* BOE 2014–2024 según estándar OCDS, con especial foco en el dominio CPV 71, e identificar las variables más relevantes para la detección de red flags (Muñoz Plà, 2026; Open Contracting Partnership, 2024b).

Métricas de éxito verificables:

- Documento de análisis exploratorio que acredita completitud, coherencia temporal y distribución de variables OCDS en el dominio CPV 71.
- Matriz de relevancia: mapeo de campos OCDS → indicadores de red flags RF-01 a RF-15, con justificación bibliográfica de cada asignación.
- Mínimo 3 fuentes de datos complementarias identificadas y documentadas (ROLE-CE, registros mercantiles, TED).

OE2 — Diseño del modelo de datos analítico

Descripción: Definir e implementar un esquema de datos integrado y armonizado con el estándar OCDS (Open Contracting Partnership, 2024a) que unifique información de contratos, licitaciones, adjudicatarios, órganos contratantes y relaciones societarias, como fundamento del análisis de redes y del motor de red flags.

Métricas de éxito verificables:

- Modelo Entidad-Relación documentado en PostgreSQL con mínimo 6 entidades principales y claves externas verificadas.
- Grafo empresa-organismo-contrato construido en Neo4j con coherencia estructural demostrable.
- Completitud de campos OCDS críticos ≥ 85 % tras el proceso de normalización.

OE3 — Construcción del *pipeline* de datos

Descripción: Implementar un *pipeline* reproducible de descarga, limpieza, normalización, enriquecimiento y carga de datos OCDS, con validación automática de calidad y trazabilidad de fuentes, que garantice la reproducibilidad integral del proceso (World Bank, 2021).

Métricas de éxito verificables:

- *Pipeline* ejecutable y documentado (Python + Pandas + DuckDB) con tests automáticos de calidad.
- Completitud OCDS post-carga > 90 % en campos críticos; coherencia temporal > 98 %.
- Tiempo de ejecución completo < 2 horas para el *dataset* BOE 2014–2024.

OE4 — Desarrollo del motor de red flags

Descripción: Diseñar e implementar un conjunto de mínimo 15 indicadores de red flags (RF-01 a RF-15) basados en la taxonomía de la OCP (Open Contracting Partnership, 2024b) y en Fazekas y Cingolani (2020), complementados con tres enfoques de machine learning para scoring de riesgo compuesto: reglas explícitas, Isolation Forest y Positive-Unlabeled Learning.

Métricas de éxito verificables:

- Mínimo 15 indicadores documentados con umbral, lógica de cálculo y fundamento bibliográfico.
- Modelo de scoring compuesto que combina flags individuales con métricas de red.
- Precisión $> 70\%$ en un conjunto de casos con *ground truth* parcial (contratos con resoluciones judiciales o denuncias públicas documentadas).
- Comparativa de los tres enfoques ML con métricas de AUC-ROC, precisión y estabilidad en validación cruzada.

OE5 — Módulo de análisis de redes

Descripción: Construir y analizar el grafo bipartito empresa-organismo-contrato para detectar comunidades (algoritmo Leiden (Traag y cols., 2019)), patrones de centralidad atípicos y posibles relaciones societarias de riesgo en el dominio CPV 71, correlacionando las métricas de red con los scores del motor de red flags.

Métricas de éxito verificables:

- Grafo construido con mínimo 2.031 nodos empresa y 394 organismos del dominio CPV 71.
- Ejecución del algoritmo Leiden con modularidad $Q > 0,30$.
- Identificación documentada de mínimo 5 patrones de concentración atípica.
- Correlación estadísticamente significativa ($\rho \geq 0,45$, $p < 0,05$) entre score de centralidad de red y score de red flags por empresa.

OE6 — Módulo NLP y recuperación documental

Descripción: Implementar un sistema de extracción de información estructurada sobre pliegos de prescripciones técnicas y resoluciones de adjudicación del dominio CPV 71 mediante OCR (Docling (IBM Research, 2024)), NER en español (spaCy (Honnibal y cols., 2020)) y motor RAG híbrido (Qdrant + BM25 + BGE-M3 (BAAI, 2024)).

Métricas de éxito verificables:

- Corpus de mínimo 5.000 documentos procesados con Docling y almacenados en el *vector store*.

- NER en español con precisión $> 75\%$ en entidades críticas (organismos, empresas, importes, códigos CPV).
- Motor RAG con Faithfulness $> 0,80$ y Answer Relevancy $> 0,75$ (RAGAS).
- Tiempo de recuperación de contexto por caso < 5 segundos.

OE7 — Desarrollo del *front-end* analítico

Descripción: Construir una interfaz web interactiva (Streamlit + Sigma.js + Plotly) con grafo de relaciones, panel de indicadores de riesgo por caso, *timeline* de evolución temporal y ficha de riesgo explicable generada automáticamente con SHAP (Nallakaruppan y cols., 2025) y contexto documental recuperado por el motor RAG.

Métricas de éxito verificables:

- Puntuación SUS (*System Usability Scale*) > 68 en evaluación con mínimo 5 usuarios de perfil analista técnico.
- Tiempo medio para localizar y documentar un caso de riesgo < 5 minutos.
- Ficha explicativa evaluada con claridad $\geq 3,5/5$ (escala Likert) por los mismos evaluadores.

OE8 — Evaluación integral del sistema

Descripción: Validar el prototipo mediante métricas cuantitativas de calidad del *pipeline* (completitud OCDS), precisión del motor de red flags, modularidad del grafo, métricas RAG y usabilidad, y análisis cualitativo de mínimo 10 casos de riesgo en el dominio CPV 71 con *ground truth* verificable.

Métricas de éxito verificables:

- Informe de evaluación con todas las métricas especificadas en OE1–OE7.
- Fichas documentadas de mínimo 10 casos de riesgo analizados, con descripción del patrón detectado, indicadores activados y valoración de la explicación generada.
- Documento de limitaciones identificadas y *roadmap* de mejora para trabajo futuro.

5. Marco Normativo

El diseño de ProcureWatch Analytics se enmarca en un conjunto de disposiciones normativas españolas y europeas que condicionan tanto el tratamiento de los datos como la arquitectura del sistema de scoring:

Ley 9/2017 de Contratos del Sector Público (LCSP) (Jefatura del Estado, 2017)

Marco regulatorio fundamental de la contratación pública española. Define tipos de contrato, procedimientos, umbrales de publicidad obligatoria y los límites del contrato menor. Su artículo 205 regula las modificaciones contractuales justificadas, clave para la calibración del indicador RF-03 (desviación de importe) en sectores donde las modificaciones son frecuentes por causas legítimas (e.g., obras frente a servicios de ingeniería).

Directiva 2014/24/UE del Parlamento Europeo y del Consejo (European Parlia-

ment and Council, 2014) Marco europeo de contratación pública que establece los principios comunitarios de concurrencia, transparencia, igualdad de trato y proporcionalidad. Define los umbrales de publicidad obligatoria en el DOUE (Diario Oficial de la UE), por encima de los cuales los contratos se publican también en TED.

Ley 19/2013 de transparencia, acceso a la información pública y buen gobierno

(Jefatura del Estado, 2013) Establece la obligación de publicar activamente la información sobre contratos del sector público y define las condiciones de reutilización. Fundamenta jurídicamente el uso de datos publicados en PLACE y el BOE para análisis científicos y de supervisión.

Reglamento General de Protección de Datos (RGPD) y Ley Orgánica de Protección de Da-

Los datos de contratación incluyen información de carácter personal (NIF de personas físicas que actúan como administradores o representantes). ProcureWatch opera exclusivamente sobre datos publicados en el marco de obligaciones legales de transparencia, lo que encuadra su tratamiento en la base jurídica del art. 6.1.c RGPD (cumplimiento de una obligación legal). El sistema no trata datos personales sensibles ni elabora perfiles individuales sin base legal específica.

Reglamento (UE) 2024/1689 de Inteligencia Artificial (AI Act) (European Par-

liament and Council, 2024) Clasifica como **sistemas de alto riesgo** (Anexo III, sec-

ción 8) los sistemas que generen puntuaciones o clasificaciones de riesgo que puedan influir en decisiones sobre el acceso de empresas a contratos públicos. En consecuencia, ProcureWatch está diseñado con: (a) trazabilidad completa del razonamiento del sistema para cada score generado; (b) documentación técnica conforme al artículo 11; (c) registro automático de eventos (artículo 12); y (d) supervisión humana obligatoria: el sistema genera fichas de riesgo para revisión humana, sin capacidad de adoptar decisiones automáticas vinculantes (artículo 14).

6. Conclusiones y Trabajo Futuro

[A desarrollar en la fase final del TFM, tras la implementación y evaluación del prototipo sobre el dominio CPV 71.]

Referencias

- Agencia Tributaria de España. (2023). *Desarticulada una trama de fraude en la contratación de obra pública en cantabria*. Descargado de https://sede.agenciatributaria.gob.es/Sede/Desarticulada_una_trama_de_fraude_en_la_contratacion_de_obra_publica_en_Cantabria.htm
- Alibaba Cloud. (2024). *Qwen3: Technical report*. Descargado de <https://huggingface.co/Qwen>
- Almeida, J., y cols. (2025). Data-driven transparency: Machine learning and social network analysis for corruption detection in public procurement. *Procedia Computer Science*. Descargado de <https://www.sciencedirect.com/science/article/pii/S1877050925029722>
- BAAI. (2024). *BGE-M3: Multi-functionality, multi-linguality, multi-granularity text embeddings*. Descargado de <https://huggingface.co/BAAI/bge-m3>
- Blondel, V., y cols. (2024). Fast leiden algorithm for community detection in shared memory. En *Proceedings of the 53rd international conference on parallel processing (icpp 2024)*. ACM. Descargado de <https://dl.acm.org/doi/10.1145/3673038.3673146> doi: 10.1145/3673038.3673146
- Coviello, D., y Mariniello, M. (2023). Corruption red flags in public procurement: New evidence from Italian calls for tenders. *EPJ Data Science*, 11(1), 7. Descargado de <https://link.springer.com/article/10.1140/epjds/s13688-022-00325-x> doi: 10.1140/epjds/s13688-022-00325-x
- European Parliament and Council. (2014). *Directive 2014/24/EU of the European Parliament and of the council of 26 february 2014 on public procurement*. Descargado de <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32014L0024>
- European Parliament and Council. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act)*. Descargado de <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32024R1689>

- Falcón-Cortés, A., Aldana, A., y Larralde, H. (2021). Practices of public procurement and the risk of corrupt behavior. *arXiv preprint*. Descargado de <https://arxiv.org/abs/2108.02653>
- Fazekas, M., y Cingolani, L. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using government contracting data. *British Journal of Political Science*, 50(1), 155–164. Descargado de https://ideas.repec.org/a/cup/bjposi/v50y2020i1p155-164_7.html doi: 10.1017/S0007123419000425
- Fazekas, M., y Cingolani, L. (2025). *Opentender: Public procurement data for transparency and accountability* (Inf. Téc.). Government Transparency Institute. Descargado de <https://www.govtransparency.eu/opentender/>
- Fazekas, M., y cols. (2025). Detection of fraud in public procurement: A systematic mapping study. *EPJ Data Science*. Descargado de <https://link.springer.com/article/10.1140/epjds/s13688-025-00569-3> doi: 10.1140/epjds/s13688-025-00569-3
- Government Transparency Institute. (2021). *DIGIWHIST: Digital whistleblowing as a tool for reporting corruption in the EU* (Inf. Téc.). European Commission, Horizon 2020. Descargado de <https://digiwhist.eu/>
- Government Transparency Institute. (2024). *Opentender.eu — european public procurement data portal*. Descargado de <https://opentender.eu/>
- Honnibal, M., Montani, I., y Van Landeghem, S. (2020). *spaCy: Industrial-strength natural language processing in python*. Descargado de <https://spacy.io/>
- IBM Research. (2024). *Docling: An efficient and flexible document conversion library*. Descargado de <https://github.com/docling-project/docling>
- Ivalua. (2024). *Procurement dashboard: Kpis, benchmarks and visual tips*. Descargado de <https://www.ivalua.com/blog/procurement-dashboard/>
- Jefatura del Estado. (2013). *Ley 19/2013, de 9 de diciembre, de transparencia, acceso a la información pública y buen gobierno*. Descargado de <https://www.boe.es/eli/es/1/2013/12/09/19> (BOE núm. 295, de 10 de diciembre de 2013)
- Jefatura del Estado. (2017). *Ley 9/2017, de 8 de noviembre, de contratos del sector público*. Descargado de <https://www.boe.es/eli/es/1/2017/11/08/9/con> (BOE núm. 272, de 9 de noviembre de 2017)
- Kalamkar, P., y cols. (2024). Natural language processing for the legal domain: A survey of tasks, datasets, and techniques. *arXiv preprint*. Descargado de <https://arxiv.org/>

pdf/2410.21306

LangChain AI. (2024). *LangGraph: Build stateful, multi-actor applications with llms*.

Descargado de <https://github.com/langchain-ai/langgraph>

Leitner, E., y cols. (2020). Fine-grained named entity recognition in legal documents. En *Proceedings of the 17th extended semantic web conference (eswc 2020)*. Springer.

Descargado de https://link.springer.com/chapter/10.1007/978-3-030-33220-4_20 doi: 10.1007/978-3-030-33220-4_20

Liu, Y., y cols. (2023). Pattern mining for anomaly detection in graphs: Application to fraud in public procurement. *Lecture Notes in Computer Science*. Descargado de <https://arxiv.org/abs/2306.10857> doi: 10.1007/978-3-031-43427-3_5

Martins, P., y cols. (2022). Network analysis for fraud detection in Portuguese public procurement. *ResearchGate Preprint*. Descargado de https://www.researchgate.net/publication/346484234_Network_Analysis_for_Fraud_Detection_in_Portuguese_Public_Procurement

Ministerio de Hacienda y Función Pública. (2024). *Plataforma de contratación del sector público: datos abiertos de licitaciones* (Inf. Téc.). Gobierno de España. Descargado de https://www.hacienda.gob.es/es-ES/GobiernoAbierto/DatosAbiertos/Paginas/licitaciones_plataforma_contratacion.aspx

Mistral AI. (2025). *Mistral small 3*. Descargado de <https://mistral.ai>

Muñoz Plà, M. (2026). A decade of public procurement in Spain: A longitudinal open dataset from the boe (2014-2024). *arXiv preprint*. Descargado de <https://arxiv.org/abs/2602.16731>

Nallakuruppan, M. K., y cols. (2025). A perspective on explainable artificial intelligence methods: SHAP and LIME. *Advanced Intelligent Systems*. Descargado de <https://advanced.onlinelibrary.wiley.com/doi/10.1002/aisy.202400304> doi: 10.1002/aisy.202400304

Ng'ang'a, K. (2025). A hybrid machine learning model for detecting and preventing corruption in Kenya's public procurement contracts. *Machine Learning Research*, 10(2). Descargado de <https://www.sciencepublishinggroup.com/article/10.11648/j.ml.20251002.14> doi: 10.11648/j.ml.20251002.14

Noé, J., y cols. (2020). GraphSIF: Analyzing flow of payments in b2b networks for supplier impersonation detection. *Applied Network Science*, 5, 70. Descargado de <https://appliednetsci.springeropen.com/articles/10.1007/s41109>

-020-00283-1 doi: 10.1007/s41109-020-00283-1

Ocampo-Gutiérrez, F., y cols. (2019). Anomaly detection in public procurements using the open contracting data standard. En *Ceur workshop proceedings* (Vol. 2369).

Descargado de <https://ceur-ws.org/Vol-2369/short09.pdf>

OECD. (2016). *Preventing corruption in public procurement*. OECD Publishing. doi: 10.1787/9789264251762-en

Oficina Independiente de Regulación y Supervisión de la Contratación. (2025). *Informe anual de supervisión de la contratación pública (ias 2024)*. Descargado de <https://www.hacienda.gob.es/es-ES/Oirescon/Paginas/ias.aspx>

Open Contracting Partnership. (2016). *Red flags for integrity: Giving the green light to open data solutions* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2016/11/OCP2016-Red-flags-for-integrityshared-1.pdf>

Open Contracting Partnership. (2023). *How open is public procurement data in the eu? 2023* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2023/06/OCP2023-EU-OpenData.pdf>

Open Contracting Partnership. (2024a). *Open contracting data standard v1.1.5* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://standard.open-contracting.org/>

Open Contracting Partnership. (2024b). *Red flags in public procurement: A guide to using data to detect corruption and fraud* (Inf. Téc.). Open Contracting Partnership. Descargado de <https://www.open-contracting.org/wp-content/uploads/2024/12/OCP2024-RedFlagProcurement-1.pdf>

Pedregosa, F., y cols. (2011). *Scikit-learn: Machine learning in python — IsolationForest*. Descargado de <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html>

PkgPulse. (2026). *Cytoscape.js vs vis-network vs sigma.js: Graph visualization comparison 2026*. Descargado de <https://www.pkgpulse.com/blog/cytoscape-vs-vis-network-vs-sigma-graph-visualization-javascript-2026>

Portal de Contratación Pública. (2026). *Lista de códigos CPV 71x: Servicios de arquitectura, construcción, ingeniería e inspección*. Descargado de <https://www.publictendering.com/cpv-codes/lista-de-los-codigos-cpv/71x/>

Su, X., y cols. (2021). Positive-unlabeled learning from imbalanced data. En *Procee-*

dings of the 30th international joint conference on artificial intelligence (ijcai-21).

Descargado de <https://www.ijcai.org/proceedings/2021/412>

Traag, V. A., Waltman, L., y van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9(1), 5233. Descargado de <https://www.nature.com/articles/s41598-019-41695-z> doi: 10.1038/s41598-019-41695-z

Wachs, J., Fazekas, M., y Kertész, J. (2025). A machine learning and network science approach to identifying corruption risks in public procurement. *arXiv preprint*. Descargado de <https://arxiv.org/abs/2512.19491>

World Bank. (2021). *Open contracting data standard: Implementation guide* (Inf. Téc.). World Bank Group. Descargado de <https://documents1.worldbank.org/curated/en/744551614955316901/pdf/Open-Contracting-Data-Standard.pdf>

Zhang, W., y cols. (2023a). Fraud detection via contrastive positive unlabeled learning. *IEEE Conference Publication*. Descargado de <https://ieeexplore.ieee.org/document/10020693/> doi: 10.1109/ICDM54844.2023.00001

Zhang, W., y cols. (2023b). Group-based fraud detection network on e-commerce platforms. En *Proceedings of the 29th acm sigkdd conference on knowledge discovery and data mining (kdd 2023)*. ACM. Descargado de https://cgi.cse.unsw.edu.au/~zhangw/files/2023_KDD_paper.pdf

A. Apéndice A: Subtipos CPV 71

incluidos en el análisis

La Tabla A.1 recoge los códigos de la división CPV 71 incluidos en el *dataset* de validación del prototipo, con su descripción oficial y la presencia en el dataset BOE 2014–2024.

Tabla A.1: Subtipos CPV 71 relevantes para ProcureWatch Analytics		
Código CPV	Descripción	Nivel
71000000	Servicios de arquitectura, construcción, ingeniería e inspección	División
71100000	Servicios de arquitectura y conexos	Grupo
71200000	Servicios de arquitectura y servicios conexos	Grupo
71300000	Servicios de ingeniería	Grupo
71311000	Consultoría en ingeniería civil	Clase
71312000	Consultoría en ingeniería de estructuras	Clase
71313000	Consultoría en ingeniería medioambiental	Clase
71320000	Servicios de diseño técnico	Clase
71340000	Servicios integrados de ingeniería	Clase
71350000	Servicios científicos y técnicos en ingeniería	Clase
71356000	Servicios técnicos	Categoría
71500000	Servicios relacionados con la construcción	Grupo
71600000	Servicios de pruebas, inspección y control técnico	Grupo
71700000	Servicios de supervisión e inspección	Grupo

Fuente: Portal de Contratación Pública (2026); elaboración propia a partir del dataset BOE 2014–2024 (Muñoz Plà, 2026).

B. Apéndice B: Indicadores de red flags implementados (RF-01 a RF-15)

La Tabla B.1 describe los 15 indicadores de red flags del motor analítico de ProcureWatch, con el fundamento bibliográfico, el campo OCDS requerido y el umbral de activación propuesto.

Tabla B.1: Indicadores de red flags RF-01 a RF-15

ID	Descripción	Campo OCDS	Umbral	Referencia
RF-01	Licitación única	<code>bidsStatistics</code>	1 oferta	Open Contracting Partnership (2024b)
RF-02	Concentración de adjudicatario por organismo	<code>awards.suppliers</code>	>40 %	Fazekas y Cingolani (2020)
RF-03	Desviación importante estimado/adjudicado	<code>value</code> <code>award.value</code>	vs >20 %	Coviello y Mariniello (2023)
RF-04	Plazo de resolución anormalmente corto	<code>tenderPeriod</code>	<10 días	Open Contracting Partnership (2024b)

Tabla B.1 (continuación)

ID	Descripción	Campo OCDS	Umbral	Referencia
RF-05	Recurrencia del mismo proveedor (negociado)	<code>procurementMethod</code>	>3 veces/año	Oficina Independiente de Regulación y Supervisión de la Contratación (2025)
RF-06	Contrato menor cerca del umbral	<code>value.amount</code>	>90 % umbral	Oficina Independiente de Regulación y Supervisión de la Contratación (2025)
RF-07	Publicación en período de baja visibilidad	<code>tender.tenderPeriodStart/Date</code>	<code>IsAntiCompetitive</code>	Open Contracting Partnership (2016)
RF-08	Modificación contractual injustificada	<code>contracts.amendments</code>	>10 %	Open Contracting Partnership (2024b)
RF-09	Criterios subjetivos >49 % puntuación	Texto pliego (NLP)	>49 %	Kalamkar y cols. (2024)
RF-10	Concentración en organismo-empresa	Grafo	$Q_{\text{local}} > 0,30$	Traag y cols. (2019)
RF-11	Empresa con centralidad atípica en red	Grafo betweenness	Top 1 %	Wachs y cols. (2025)
RF-12	UTE con composición recurrente	Grafo + <code>suppliers</code>	>3 veces	Elaboración propia

Tabla B.1 (continuación)

ID	Descripción	Campo OCDS	Umbral	Referencia	
RF-13	Plazo de ejecución anormalmente corto	<code>contractPeriod</code>	<P5 dominio	Open Contracting Partnership (2024b)	Con-
RF-14	Ausencia de publicidad en TED (sobre umbral UE)	<code>tender.mainProcurementAppCategory</code>		European Parliament and Council (2014)	
RF-15	Proveedor sin historial previo en dominio	<code>awards.suppliers.id</code>	Primera vez	Falcón-Cortés y cols. (2021)	